宮兮 주간 보고서 — STT 파트 (안기겸)

보고 기간 2026. 10. 29 (목) ~ 11. 4 (수) · 작성 안기겸 · PM 통합본의 6장·부록 C 자리에 넣는 원고

1. 이번 보고서 요약 (STT 항목)

- STT: 소음·동시 발화 환경에서 Amazon Transcribe 인식률과 VAD(음성 구간 검출) 성능을 녹음 180개 합성 데이터로 측정. 웅성거림은 해설사 목소리보다 10 dB 작으면 CER 4.45%(깨끗 3.73%)로 유지되나, 옆 사람 1명이 10 dB 차이로 말하면 CER 8.26%로 2배. VAD는 Silero + 음량 문턱 구성으로 확정
- STT→번역 스트리밍 파이프라인(VAD → Transcribe → 후처리 사전 → Translate → 카드 링크) 패키지 `gunggeum_stt` 구축 완료(영어 우선, 단위 테스트 13개 통과). 자막 지연·번역 품질 측정은 해커톤 참가로 미진행, 다음 주 수행

6. STT 소음·VAD 측정 및 실시간 자막 파이프라인 구축 (안기겸)

6-1. 수행 내용

- 10/25 확정한 Amazon Transcribe 구성(위치별 사용자 지정 어휘 + 후처리 사전)이 현장 소음에서 얼마나 버티는지 측정함. 기존 녹음 180개가 모두 조용한 실내 낭독이라, 녹음끼리 합성해 배경 소리를 만듦: 군중 웅성거림(다른 낭독자 6명 녹음을 겹침)을 해설사 목소리보다 20·10·5·0 dB 작게, 옆 사람 1명(다른 낭독자 1명 녹음을 같은 구간에 겹침)을 10·5·0 dB 작게 섞은 7조건 × 180개.
- VAD 후보 비교: Silero VAD(문턱 0.5·0.7), WebRTC VAD(모드 3), Silero + 음량 문턱(–10·–15 dB), Silero + 음량 문턱 + 시작 0.1초/유지 0.3초. 녹음 앞뒤에 무음 구간을 붙이고 배경을 깔아 "해설사가 쉬는 동안 배경에 켜지는지"를 측정함.
- 아키텍처 v0.3(6.3 실시간 통역 처리 흐름)에 맞춰 STT→번역 스트리밍 파이프라인을 파이썬 패키지 `gunggeum_stt`로 구현함(gunggeum-ai-stt 저장소). 실시간 통역 컨테이너(김병진)가 import해 쓰는 형태이며, 시험용 WebSocket 서버와 지연 측정 클라이언트, 단위 테스트 13개를 포함함.
- 자막 번역·카드 링크의 영문 표기는 `경복궁_전각.xlsx`(name_en)· `경복궁_용어.xlsx`("영문 표기 (작성용)")를 원본으로 삼고, 엑셀 → 데이터 변환 스크립트와 일치 검사를 넣음(전각 71 + 용어 231 = 카드 302장, Translate 용어집 329행). RAG DB의 표기와 302장 모두 일치함을 확인함.
- 자막 지연(문장 끝 → 자막 3초, N4)·태국어 용어집 품질·현장 소음 측정은 해커톤 참가로 진행하지 못함. 파이프라인 동작 확인(녹음 20개, 번역 제외)만 수행함.

6-2. 결과: 배경 소리 세기별 인식률 (Amazon Transcribe + 위치별 어휘 + 후처리 사전)

배경	해설사 대비 세기 차이 (dB)	CER (%) ↓	완전 일치 (%) ↑	붕괴 발화 (개, CER≥50%) ↓	용어 인식률 (%) ↑	전각명 인식률 (%) ↑
깨끗한 녹음 (기준)	—	3.73	41.1	0	94.2	96.2
웅성거림	20	3.89	40.6	0	93.1	96.2
웅성거림	10	4.45	33.3	0	92.2	94.7
웅성거림	5	9.11	17.8	0	82.8	84.2
웅성거림	0	40.39	7.8	63	53.5	57.9
옆 사람 1명	10	8.26	27.8	4	88.6	88.7
옆 사람 1명	5	24.42	12.8	29	74.1	78.9
옆 사람 1명	0	62.07	0.6	107	43.0	47.4

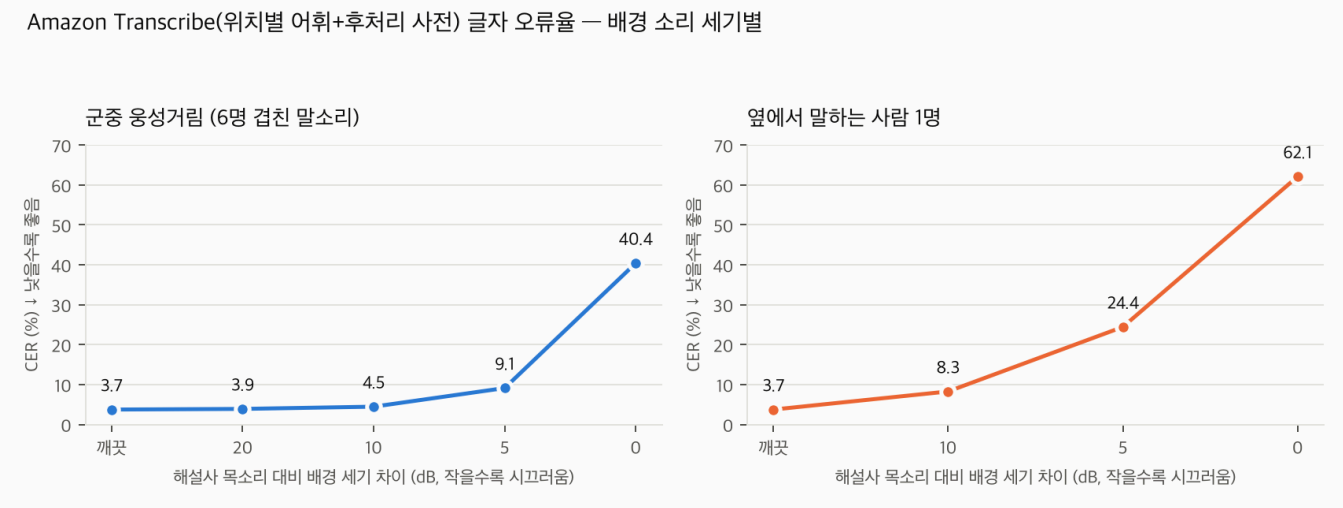


그림 1. 배경 소리 세기별 CER (왼쪽 웅성거림, 오른쪽 옆 사람 1명)

- 웅성거림은 10 dB까지 깨끗한 녹음과 사실상 같음(CER 차이 0.7%p 이내, 붕괴 0건). 5 dB부터 전각명 84%, 0 dB에서는 180개 중 63개 붕괴.
- 옆 사람 1명은 같은 세기 차이의 웅성거림보다 2~3배 나쁨. 또렷한 한국어라 Transcribe가 두 사람의 말을 섞어 받아쓰기 때문(전사 길이는 정답과 같은데 내용이 섞임).
- 대기 시간은 조건과 무관하게 평균 1.25초, p90 1.7초로 깨끗한 녹음과 같음.

6-3. 결과: VAD — 배경 말소리는 어떤 VAD도 해설사와 구분하지 못함

해설사가 쉬는 동안 배경 소리에 켜진 파일 비율 (%, 0.3초 이상 연속) ↓

검출기	깨끗	웅성 20	웅성 10	웅성 5	웅성 0	옆 사람 10	옆 사람 5	옆 사람 0
Silero VAD (문턱 0.5)	0.0	68.9	97.8	99.4	100.0	99.4	100.0	100.0
WebRTC VAD (모드 3)	0.0	45.0	76.7	91.1	98.3	93.3	100.0	100.0
Silero + 음량 문턱 −10 dB	0.0	0.0	37.2	97.2	100.0	28.3	84.4	95.0
Silero + 음량 문턱 −10 dB + 시작 0.1초/유지 0.3초	0.0	0.6	96.1	99.4	100.0	99.4	100.0	100.0

해설사 발화 프레임 검출률 (%) ↑

검출기	깨끗	웅성 20	웅성 10	옆 사람 10
Silero VAD (문턱 0.5)	96.7	98.6	99.8	99.5
WebRTC VAD (모드 3)	91.4	91.7	93.2	96.2
Silero + 음량 문턱 −10 dB	70.1	71.1	85.0	80.9
Silero + 음량 문턱 −10 dB + 시작 0.1초/유지 0.3초	96.4	96.7	99.2	98.6

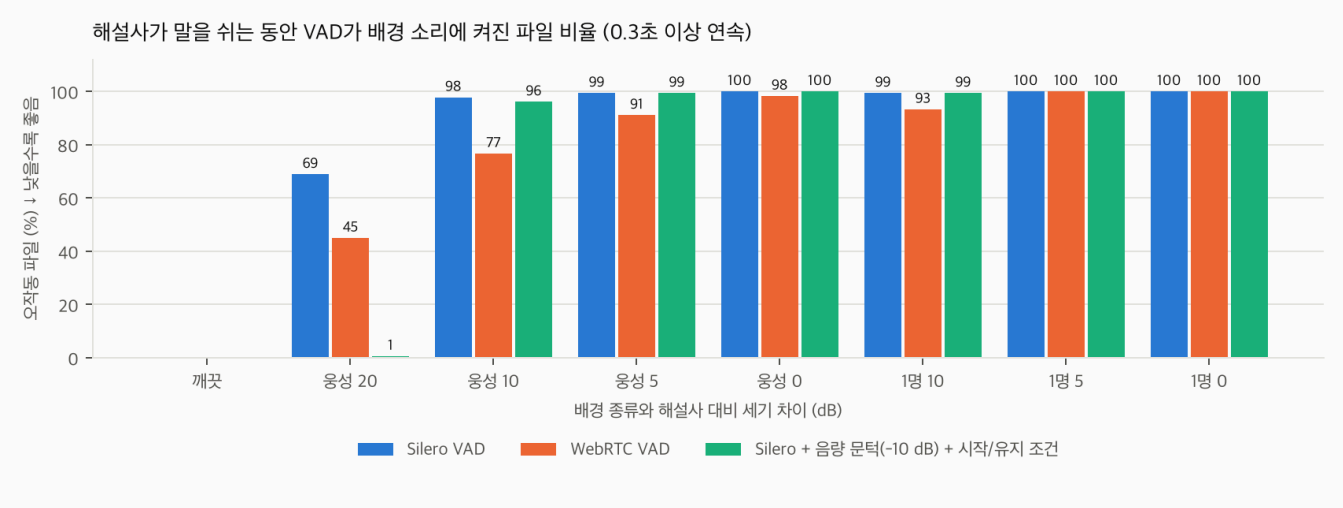


그림 2. 해설사가 쉬는 동안 VAD가 배경 소리에 켜진 파일 비율

- Silero·WebRTC 모두 배경 말소리를 "말"로 봄. 20 dB 웅성거림에서도 쉬는 구간의 45~69%가 오작동.
- 음량 문턱(해설사 발화 세기 기준 −10 dB)만 붙이면 오작동은 막히나 작은 음절이 잘려 검출률 70%. 시작 0.1초/유지 0.3초 조건을 더하면 검출률 96~97%를 되찾으면서 20 dB에서 오작동 0.6%.
- 10 dB 이하에서는 어떤 조합도 배경 말소리를 막지 못함. 처리 속도는 Silero 46 ms, WebRTC 1 ms(10초 파일, CPU)로 둘 다 실시간에 문제없음.

6-4. 결정: 설계 반영 사항

순서	할 일	근거
1	해설사 마이크를 입 가까이(헤드셋·핀마이크)로 두어 배경 대비 10 dB 이상 확보	10 dB 이상이면 CER·전각명이 깨끗한 녹음과 같음
2	VAD는 Silero + 음량 문턱 −10 dB + 시작/유지 조건으로, "조용할 때 전송 차단" 용도로만 사용	20 dB 환경에서 오작동 0.6%·검출 97%. 쉬는 동안 Transcribe 과금 없음, 엉뚱한 자막 방지
3	시끄러운 곳에서는 해설사가 말하기 버튼으로 켜고 끄는 수동 방식을 기본으로	10 dB 이하에서는 어떤 VAD도 화자 구분 불가
4	11/8 현장 테스트에서 앱이 해설사 발화 세기·배경 세기를 로그로 남김	실제 현장이 20·10·5 dB 중 어디인지 알아야 2·3의 기본값 확정 가능

6-5. 결과: STT→번역 스트리밍 파이프라인 구축

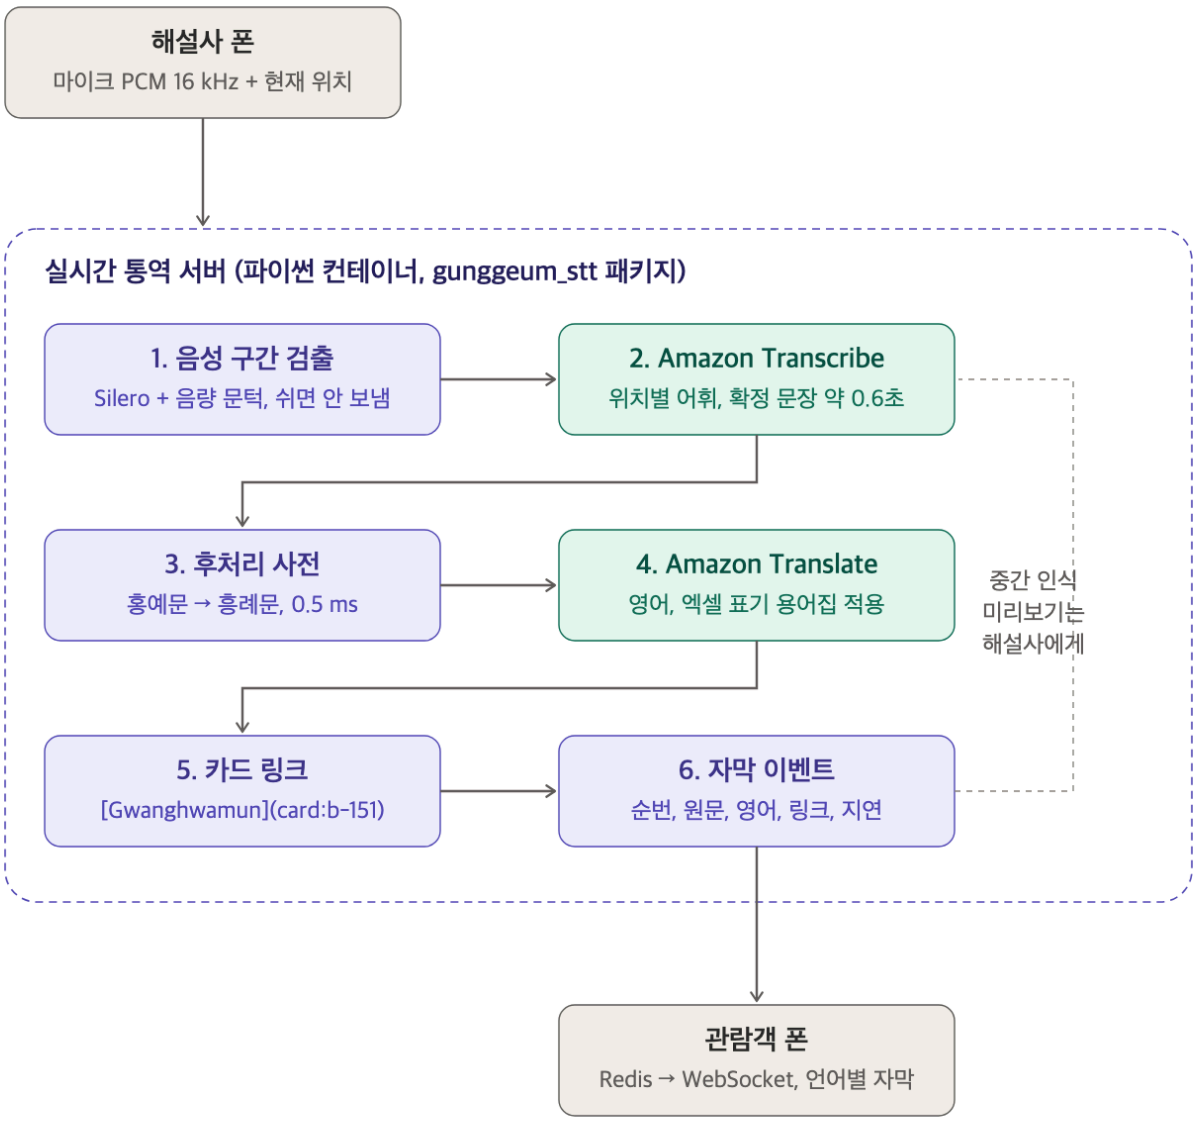


그림 3. 실시간 자막 파이프라인 (보라색: 서버 안 파이썬 코드, 청록색: AWS 서비스 호출)

단계	모듈	하는 일	걸리는 시간
1. 음성 구간 검출	`vad.py`	Silero VAD(onnx, torch 불필요) + 음량 문턱 –10 dB + 시작 0.1초/유지 1.5초. 말이 시작되면 0.3초 전부터 Transcribe로 보내고, 1.5초 넘게 조용하면 연결을 닫음(쉬는 동안 과금 없음, 마지막 문장 확정)	조각당 1 ms 미만
2. Amazon Transcribe	`transcribe.py`	서울 리전 스트리밍 ko-KR, 위치별 사용자 지정 어휘(`gungeum-loc-00~25`). 해설 위치가 바뀌면 다음 연결부터 그 위치 어휘. 중간 결과는 해설사 미리보기로	말 끝 뒤 약 0.6초
3. 후처리 사전	`postcorrect.py`	위치별 용어와 자모 단위 유사도 0.85 이상이면 교정 (벤치마크 v2 설정 그대로)	0.5 ms
4. Amazon Translate	`translate.py`	언어별 병렬 호출, 사용자 지정 용어집 `gungeum-ko` (329행)로 전각·용어 표기 고정, 같은 문장 캐시	미측정

단계	모듈	하는 일	걸리는 시간
5. 카드 링크	`cards.py`	RAG 답변과 같은 규칙(`link_names`)으로 처음 나온 전각·용어 이름에 `[Gwanghwamun](card:b-151)`	1 ms 미만
6. 자막 이벤트	`pipeline.py`	`{seq, ko, text.en, links, ms}` — 순번·원문·영어·링크·단계별 지연. Redis/WebSocket 중계는 백엔드 컨테이너 몫	즉시

- 자막 언어는 영어를 기본으로 하고, 태국어는 용어집 품질 검증 뒤 `"th"`만 더해 추가함.
- 시험용 WebSocket 서버(`/ws/guide`, `/ws/listen`, `REDIS_URL` 있으면 `live:<session>` 채널 발행)와 녹음을 실제 속도로 흘려 넣는 지연 측정 클라이언트를 함께 구현함.
- 동작 확인(녹음 20개, 번역 제외): 말 끝 → 확정 문장 평균 0.62초, p90 0.76초. 목표(문장 끝 → 자막 3초) 중 STT 몫이 0.8초라 번역을 더해도 여유가 있음.

6-6. 다음 주 계획

- 자막 지연 측정(N4 3초): Translate 용어집 등록 후 녹음 180개로 문장 끝 → 영어 자막 지연과 용어 표기 적용률 측정 (해커톤으로 미뤄진 항목).
- 태국어 용어집 품질 검증 후 태국어 자막 추가.
- 백엔드 실시간 통역 컨테이너에 `gunggeum_stt` 패키지 연결(김병진 협업), Redis 채널·메시지 형식 맞춤.
- 11/8 현장 테스트에서 해설사 발화 세기·배경 세기 로그 수집 → 소음 조건 확정.

부록 C. STT 측정 상세 (안기겸)

C-1. 소음·VAD 측정 조건

항목	내용
원 녹음	10월 벤치마크와 같은 180개(5명 낭독, 해설 위치 26곳, 16 kHz 모노)
웅성거림	같은 낭독자·같은 해설 위치를 뺀 다른 녹음 6개를 겹친 군중 소음
옆 사람 1명	다른 낭독자 1명의 녹음을 이어 붙여 해설사 발화 구간 전체에 겹침 (전체가 겹치는 최악 조건)
세기 맞추기	해설사 발화 구간(Silero VAD로 찾음)의 RMS를 재고 배경을 그보다 20·10·5·0 dB(웅성거림) / 10·5·0 dB(옆 사람) 작게 맞춤
인식 측정	원 녹음과 같은 구간, 180개 × 7조건, Transcribe + 위치별 어휘 + 후처리 사전. 비용 약 1.6달러
VAD 측정	앞 1.5초·뒤 2.5초 무음을 붙이고 배경은 그 구간에도 깔아 측정. 정답 = 깨끗한 녹음에서 Silero VAD가 찾은 발화 구간. 30 ms 프레임 단위
지표	인식: CER·완전 일치·붕괴 발화·용어/전각명 인식률. VAD: 발화 검출률, 비발화 오검출률, 무음 구간 오작동 파일 비율(0.3초 이상 연속), 시작 지연
한계	배경이 같은 녹음 세트의 한국어 낭독 합성이라 실제 현장(외국어 관람객 말소리·바람·안내 방송)과 다름. VAD 정답을 Silero로 만들어 Silero에 약간 유리

C-2. 파이프라인 동작 확인 (녹음 20개, 번역 제외, 맥북 → 서울 리전)

구성	말 끝 → 확정 평균 (ms) ↓	p90 (ms) ↓	확정 문장 수 (발화 20개)	비고
VAD 켬, 무음 1.5초 뒤 연결 닫기 (기본값)	617	756	20	문장 사이 쉼은 그대로 보내 Transcribe가 스스로 문장 끝 판정
VAD 켬, 무음 0.7초 뒤 닫기	245	387	26	닫으면 바로 확정되나 0.7초 쉼마다 문장이 잘림
VAD 끔 (항상 보냄)	589	762	20	연속 스트림, 쉬는 동안도 과금

"말 끝"은 녹음에서 말소리가 끝나는 지점(파일 끝 무음 제외)을 보낸 시각, "확정"은 Transcribe 확정 문장이 서버를 거쳐 해설사 소켓에 닿은 시각.

C-3. 산출물

파일	내용
`STT학습데이터/Benchmark/STT_소음_VAD_측정_보고서.md` / `.pdf`	소음·VAD 측정 보고서 전문
`STT학습데이터/Benchmark/mix_noise.py`, `vad_eval.py`, `results_noise/`	합성·VAD 측정 코드와 결과
`gunggeum_stt/` (gunggeum-ai-stt)	파이프라인 패키지, 시험 서버, 지연 측정 클라이언트, 테스트 13개
`경복궁_전각.xlsx`, `경복궁_용어.xlsx`, `gunggeum_stt/build_glossary.py`	영문 표기 원본과 변환 스크립트