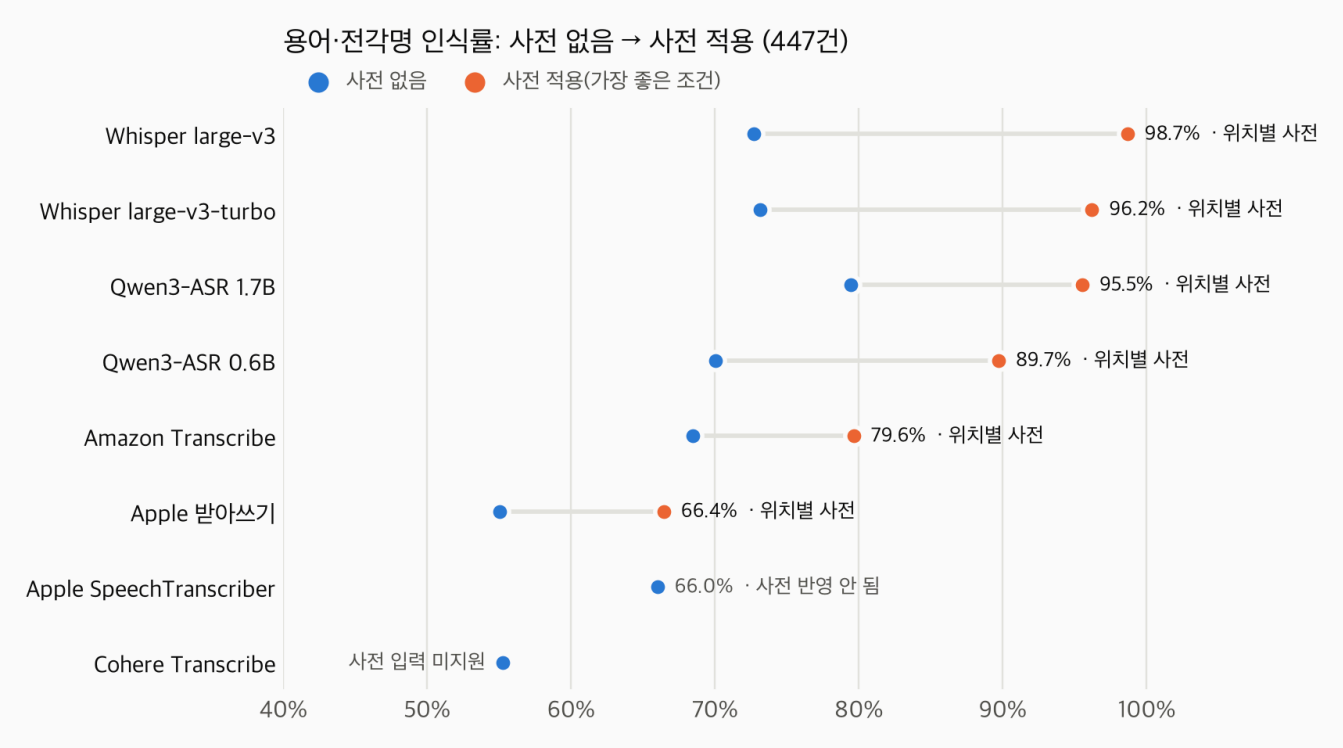
궁금(宮今) STT 벤치마크 결과 보고서

작성 안기겸 · 2026-10-24 · 경복궁 해설 발화 녹음 180개, STT 8종

1. 결론

항목	판단	근거
속도	8종 모두 PWA에서 쓰기에 충분합니다	말을 마친 뒤 결과가 나오기까지 p90 0.17~1.50초. 가장 느린 Amazon Transcribe도 2초 안에 들어옵니다.
사전 등록	**합니다. 위치별 사전 방식을 씁니다**	사전이 없으면 용어 인식률이 55~79%, 전각명 인식률이 48~72%에 그칩니다. 위치별 사전을 넣으면 Whisper large-v3가 용어 98.7%, 전각명 99.2%까지 오릅니다.
파인튜닝	**하지 않습니다**	위치별 사전을 넣은 Whisper large-v3는 CER 2.4%이고, 용어 447건 중 놓친 것은 6건입니다. 남은 오류는 대부분 숫자 표기(서른 단 ↔ 30단), 어미(돼 ↔ 되어), 띄어쓰기 차이입니다. Amazon Transcribe는 한국어 파인튜닝(사용자 지정 언어 모델)을 아예 지원하지 않습니다.
모델	Whisper large-v3-turbo + 위치별 사전	CER 2.8%, 용어 96.2%, 전각명 99.2%, 발화당 0.41초로 정확도와 속도가 가장 균형 잡혀 있습니다. AWS 관리형으로만 구성한다면 Amazon Transcribe + 위치별 사용자 지정 어휘입니다(CER 4.6%, 용어 79.6%, 전각명 69.2%, 1.19초, 분당 $0.01).

핸드폰 자체 STT에 해당하는 Apple 받아쓰기는 8종 가운데 정확도가 가장 낮았습니다. 사전이 없을 때 CER 10.0%, 용어 인식률 55.0%였습니다.



2. 측정 조건

2.1 데이터

항목	값
발화문	`경복궁_STT_발화문_300.xlsx` 중 녹음된 U0001~U0180 (180개, 해설 위치 26곳)
오디오	팀 직접 녹음 m4a(48kHz mono)를 16kHz mono PCM으로 변환
길이	총 1,363.9초, 발화당 4.2~12.8초 (중앙값 7.3초)
평가 용어	정답 문장에 나온 용어집 용어 314건 + 전각명 133건 = **447건**
난이도 태그	숫자·연도 65개, 용어 3개 이상 40개, 긴 발화(60자 이상) 15개

녹음과 발화문의 대응을 바로잡은 내역 - `U0121~U0150` : 원래 파일명이 `새로운 녹음 122~151`이었습니다. 1씩 당겨서 U0121~U0150으로 이름을 바꿨습니다. - `U0061~U0069` : 이 9개 파일에는 U0060~U0068 문장이 녹음되어 있습니다. 녹음 순서가 1칸 밀려서 U0060 문장은 두 번 녹음됐고, U0069 문장은 녹음이 없습니다. 이 9개는 실제로 녹음된 문장을 정답으로 삼았습니다. - 위 두 가지 외에는 모든 녹음이 파일명과 같은 번호의 발화문과 일치했습니다. 전체 전사 결과를 300개 발화문 전체와 대조해서 확인했습니다.

2.2 측정 모델

모델	구분	실행 방식	사전 입력 방식
Whisper large-v3	로컬(오픈 가중치)	mlx-whisper, fp16, Apple GPU	`initial_prompt` (최대 223토큰)
Whisper large-v3-turbo	로컬(오픈 가중치)	mlx-whisper, fp16, Apple GPU	`initial_prompt` (최대 223토큰)
Qwen3-ASR 1.7B	로컬(오픈 가중치)	transformers 5.20, fp16, MPS	시스템 프롬프트(context)
Qwen3-ASR 0.6B	로컬(오픈 가중치)	transformers 5.20, fp16, MPS	시스템 프롬프트(context)
Cohere Transcribe (03-2026)	로컬(오픈 가중치)	transformers 5.20, fp16, MPS	없음
Amazon Transcribe	AWS 관리형	스트리밍 API, 서울 리전, ko-KR	사용자 지정 어휘
Apple SpeechTranscriber	기기 내	SpeechAnalyzer (iOS 26·macOS 26부터)	`AnalysisContext` 문맥 문자열
Apple 받아쓰기	기기 내	SpeechAnalyzer `DictationTranscriber` (시스템 받아쓰기 계열)	`AnalysisContext` 문맥 문자열

- Apple 2종은 "핸드폰 자체 STT"를 대신해, 같은 엔진을 macOS에서 잰 값입니다.
- 이번에 측정하지 않은 것은 두 가지입니다. 기존 SFSpeechRecognizer는 측정 맥의 받아쓰기 설정이 꺼져 있어서 재지 못했고, Android 음성 인식은 측정 장비가 없었습니다.

2.3 사전 조건

조건	내용	적용 모델
없음	음성만 입력	8종 전부
위치별 사전	해설 위치마다 그 위치 발화문에 나온 전각명·용어를 빈도순으로 모은 목록입니다(위치당 5~26개, 중앙값 18개). 앱이 GPS로 현재 전각을 알고 그 구역 용어만 넣는 상황을 가정했습니다.	Whisper 2종, Qwen 2종, Apple 2종, Transcribe
전체 사전	용어집 231개(표기 변형 포함)와 전각명 71개를 합친 336개 표기	Qwen 2종, Apple 2종, Transcribe

- Whisper는 프롬프트가 최대 223토큰이라 위치별 사전만 넣었습니다. 위치별 사전은 26곳 모두 잘리지 않고 들어갔고, 전체 사전은 1,486토큰이라 넣을 수 없습니다.
- Transcribe는 스트림을 열 때 미리 만들어 둔 사용자 지정 어휘를 지정하는 방식입니다. 전체 사전 어휘 1개와 해설 위치별 어휘 26개를 만들었고, 위치별 조건에서는 발화마다 그 위치의 어휘를 지정했습니다. 어휘 형식에 맞춰 띄어쓰기는 하이픈으로, 숫자는 한글 읽기로 바꿨습니다.

2.4 지표와 장비

지표	정의
CER	공백과 문장부호를 뺀 글자 단위 편집 거리를 정답 글자 수로 나눈 값(180개 합산)입니다. 정답은 숫자를 아라비아 숫자로 적었고 모델은 둘 중 아무 표기나 낼 수 있어서, 양쪽 숫자를 모두 한자어 읽기로 바꾼 뒤 비교합니다(1395년 = 천삼백구십오년).
CER(숫자 원문)	숫자를 바꾸지 않고 잰 CER입니다.
용어 인식률	정답 문장에 나온 용어·전각명 표기가 전사 결과에 그대로 나온 비율입니다. 표기 변형 중 하나만 맞아도 인식으로 칩니다.
붕괴 발화	CER이 50% 이상인 발화 수입니다. 반복, 프롬프트 출력 같은 이상 출력을 셉니다.
대기 시간	발화 하나를 넣고 텍스트를 받기까지 걸린 시간입니다. 모델 로딩은 빼고, 첫 파일로 1회 워밍업한 뒤 잽니다.
RTF	처리 시간 합 ÷ 오디오 길이 합

- **장비**: MacBook Pro M1 Max 32GB, macOS 27.0.1. 로컬 모델 속도는 이 장비 기준입니다.
- **Transcribe 측정 방식**: 이 맥에서 서울 리전으로 오디오 조각을 쉬지 않고 보냈습니다. 대기 시간에는 연결과 네트워크 왕복 시간이 포함됩니다.
- **PWA 기준**: 말을 마친 뒤 결과가 나오기까지 2초 이내(p90)로 잡았습니다.

3. 결과

3.1 사전 없음

모델	구분	CER	CER(숫자 원문)	용어집 용어	전각명	용어 전체	붕괴	RTF	평균 대기	p90 대기
Qwen3-ASR 1.7B	로컬	**4.17%**	8.28%	**82.5%**	**72.2%**	**79.4%**	0	0.088	0.67초	0.87초
Whisper large-v3-turbo	로컬	5.12%	5.90%	76.1%	66.2%	73.2%	0	0.053	0.40초	0.43초
Whisper large-v3	로컬	5.67%	6.25%	77.1%	62.4%	72.7%	1	0.102	0.77초	0.89초
Amazon Transcribe	AWS	5.78%	5.98%	73.6%	56.4%	68.5%	0	0.144	1.09초	1.50초
Apple SpeechTranscriber	기기 내	6.11%	6.45%	69.1%	58.6%	66.0%	0	**0.019**	**0.14초**	**0.17초**
Qwen3-ASR 0.6B	로컬	6.49%	12.50%	75.5%	57.1%	70.0%	0	0.057	0.43초	0.58초
Cohere Transcribe	로컬	8.92%	9.28%	58.3%	48.1%	55.3%	0	0.056	0.42초	0.52초
Apple 받아쓰기	기기 내	9.98%	13.20%	58.0%	48.1%	55.0%	0	0.123	0.93초	1.34초

발화 유형별 CER은 다음과 같습니다(사전 없음).

모델	숫자·연도 (65개)	용어 3개 이상 (40개)	긴 발화 (15개)
Qwen3-ASR 1.7B	3.64%	3.84%	3.93%
Whisper large-v3-turbo	4.59%	5.63%	4.21%
Whisper large-v3	4.54%	5.83%	6.24%
Amazon Transcribe	5.06%	5.83%	4.48%
Apple SpeechTranscriber	5.70%	6.86%	5.56%
Qwen3-ASR 0.6B	5.96%	7.00%	5.56%
Cohere Transcribe	7.97%	10.02%	7.87%
Apple 받아쓰기	8.36%	10.50%	9.23%

- 전체 CER은 4~10%로 낮은 편입니다. 반면 고유명사는 가장 좋은 모델도 전각명 10개 중 3개 가까이를 틀립니다.
- Qwen3-ASR은 숫자를 "천삼백구십오 년"처럼 한글로 적습니다. 그래서 숫자를 맞추지 않은 CER(숫자 원문)이 두 배 가까이 높습니다.

3.2 사전 적용

모델	사전	CER	용어 전체	전각명	붕괴	평균 대기
Whisper large-v3	위치별	5.67% → **2.43%**	72.7% → **98.7%**	62.4% → **99.2%**	1 → 0	0.77 → 0.78초
Whisper large-v3-turbo	위치별	5.12% → **2.76%**	73.2% → **96.2%**	66.2% → **99.2%**	0 → 0	0.40 → 0.41초
Qwen3-ASR 1.7B	위치별	4.17% → 3.38%	79.4% → 95.5%	72.2% → 94.7%	0 → 1	0.67 → 0.70초
Qwen3-ASR 1.7B	전체	4.17% → 8.56%	79.4% → 86.1%	72.2% → 75.9%	0 → 2	0.67 → 1.44초
Qwen3-ASR 0.6B	위치별	6.49% → 3.94%	70.0% → 89.7%	57.1% → 92.5%	0 → 0	0.43 → 0.43초
Qwen3-ASR 0.6B	전체	6.49% → 5.85%	70.0% → 74.5%	57.1% → 65.4%	0 → 0	0.43 → 0.80초
Amazon Transcribe	위치별 어휘	5.78% → 4.60%	68.5% → 79.6%	56.4% → 69.2%	0 → 0	1.09 → 1.19초
Amazon Transcribe	전체 어휘	5.78% → 5.09%	68.5% → 75.8%	56.4% → 63.9%	0 → 0	1.09 → 1.20초
Apple 받아쓰기	위치별	9.98% → 8.87%	55.0% → 66.4%	48.1% → 65.4%	0 → 0	0.93 → 0.79초
Apple 받아쓰기	전체	9.98% → 9.34%	55.0% → 61.7%	48.1% → 57.9%	0 → 0	0.93 → 1.24초
Apple SpeechTranscriber	위치별·전체	변화 없음	변화 없음	변화 없음	0	0.14초
Cohere Transcribe	—	사전 입력 기능 없음				

- 사전 효과는 **위치별 사전이 전체 사전보다 큽니다.** 용어 인식률을 위치별과 전체로 비교하면 Qwen3-ASR 1.7B는 95.5%와 86.1%, Transcribe는 79.6%와 75.8%, Apple 받아쓰기는 66.4%와 61.7%였습니다.
- **Transcribe는 사전 효과가 작습니다.** 같은 위치별 사전을 넣었을 때 전각명 인식률이 Whisper는 99.2%, Transcribe는 69.2%였습니다. Transcribe는 어휘를 넣은 뒤에도 흥례문 → 흑례문(7회), 신무문 → 신문문(4회), 건춘문 → 건축문·건축물(5회)처럼 틀렸습니다.
- **전체 사전은 Qwen을 느리게 합니다.** 336개 표기를 매번 프롬프트로 넣으면 Qwen3-ASR 1.7B의 평균 대기가 0.67초에서 1.44초로 늘어납니다.
- **Apple SpeechTranscriber는 사전을 반영하지 않습니다.** 사전을 넣어도 180개 전사가 글자 하나까지 같았습니다.
- **Whisper는 사전을 넣어도 속도가 그대로입니다.**

3.3 속도

- 사전 없음 기준으로 8종 모두 p90 대기 0.17~1.50초, 최대 2.07초입니다. PWA 기준(2초)을 p90에서 모두 충족합니다.
- 로컬 모델 가운데에서는 Whisper large-v3-turbo가 가장 빠릅니다(RTF 0.053, 발화당 0.40초).
- Transcribe의 대기 1.1~1.2초에는 스트림 연결과 네트워크 왕복이 포함됩니다.

4. 오류 분석

4.1 자주 틀린 용어 (사전 없음, 8종 합산)

용어	종류	등장	오인식률	대표 오인식
홍예	용어	3	100%	홍해, 홍의
영제교	전각	2	100%	영재교
다포계	용어	2	100%	다폭의, 다포개
천록	용어	2	94%	철록
품계석	용어	3	92%	품괴석, 풍계석, 품계해석
건춘문	전각	7	91%	건축문, 건축물
강녕전	전각	8	89%	강령전, 강영전
하례	용어	2	88%	할애, 할례
드므	용어	2	88%	드무
칠조룡	용어	2	88%	7조령, 실조룡
흥례문	전각	10	84%	흥래문, 흑래문
건청궁	전각	4	81%	건천궁, 건천군
창덕궁 대화재	용어	2	81%	창덕궁 대화제
경회루	전각	6	79%	경회로, 경외로
어좌	용어	4	75%	어자, 어저

- 오인식률은 놓친 횟수를 (등장 횟수 × 8종)으로 나눈 값입니다. 2회 이상 등장한 용어만 넣었습니다.
- 대부분 소리가 비슷한 일반어로 바뀝니다(건춘문 → 건축물, 하례 → 할애, 사신 → 사진). 고유명사를 모르는 모델이 흔한 단어 쪽으로 받아 적는 패턴입니다.

4.2 사전 적용 후 남은 오류 (Whisper large-v3 + 위치별 사전)

- **놓친 용어는 447건 중 6건**입니다: 흥례문 → 홍례문, 경복궁 중건 → 경복궁을 중건, 해태 → 해트, 품계석 → 품계해석, 사신 → 사진, 신료 → 신뢰.
- 180개 중 103개(57.2%)는 정답과 완전히 같았습니다.
- 나머지 오류는 대부분 다음 유형입니다.
  - 숫자 표기: "서른 단" ↔ "30단", "마흔여덟 개" ↔ "48개"
  - 어미: "배치돼" ↔ "배치되어", "지정됐습니다" ↔ "지정되었습니다"
  - 조사·띄어쓰기: "석축 기단" ↔ "석축기단"

4.3 붕괴 발화

모델·조건	건수	내용	붕괴 제외 CER
Whisper large-v3, 사전 없음	1	같은 문장을 두 번 반복해서 출력	5.26%
Qwen3-ASR 1.7B, 위치별 사전	1	받아쓰기 대신 사전 목록을 출력	2.52%
Qwen3-ASR 1.7B, 전체 사전	2	받아쓰기 대신 사전 목록을 출력	3.51%

Qwen은 사전을 프롬프트로 넣는 구조라, 드물게 사전 목록 자체를 출력합니다. Whisper에 위치별 사전을 넣은 조건에서는 붕괴가 없었습니다.

5. 판단

5.1 사전 등록: 합니다

- 사전이 없으면 전각명 인식률이 48~72%입니다. 해설·안내 서비스에서 가장 중요한 단어인 전각명을 2~4개 중 1개꼴로 틀립니다.
- 위치별 사전을 넣으면 Whisper 2종의 전각명 인식률이 99.2%가 되고, 속도 손실도 없습니다.
- 방식은 **위치별 사전**으로 합니다. 앱이 GPS로 현재 구역을 알면 그 구역 용어만 STT에 넘깁니다. 전체 사전보다 효과가 크고, Qwen처럼 프롬프트로 사전을 넣는 모델에서 느려지거나 붕괴하는 위험도 적습니다.
- 사전 원본은 엑셀의 `용어 커버리지` (용어집 231개)와 `전각 커버리지` (전각 71개)입니다. 벤치마크에 쓴 목록은 `data/hint_terms.txt` (전체)와 `data/hints_by_location.json` (위치별)에 있습니다.

5.2 파인튜닝: 하지 않습니다

- Whisper large-v3 + 위치별 사전에서 CER은 2.43%, 놓친 용어는 447건 중 6건입니다.
- 남은 오류는 숫자 표기, 어미, 띄어쓰기 차이가 대부분입니다. 뒤에 붙는 LLM 답변이나 번역의 의미에는 영향이 없는 유형입니다.
- 사전만으로 용어 문제가 해결되므로, 학습 데이터를 만들고 학습·배포하는 데 드는 비용을 들일 근거가 이번 데이터에서는 나오지 않았습니다.

5.3 모델 선택지

선택지	구성	CER	용어 / 전각명	평균 대기	운영 형태·비용
A. 정확도 우선	Whisper large-v3-turbo + 위치별 사전	2.76%	96.2% / 99.2%	0.41초	모델을 직접 배포해 운영. AWS EC2 GPU 인스턴스나 SageMaker 엔드포인트에 올리면 AWS 구성 안에 둘 수 있음 (속도는 M1 Max 기준)
A′	Whisper large-v3 + 위치별 사전	2.43%	98.7% / 99.2%	0.78초	A와 같음. 처리 시간은 turbo의 약 2배
B. AWS 관리형	Amazon Transcribe + 위치별 사용자 지정 어휘	4.60%	79.6% / 69.2%	1.19초	서울 리전 스트리밍 초당 $0.0001667(분당 $0.01), 사용자 지정 어휘는 추가 요금 없음
C. 핸드폰 자체 STT	Apple 받아쓰기	9.98%	55.0% / 48.1%	0.93초	비용 없음. 키보드 받아쓰기로 쓰면 앱이 사전을 넘길 수 없음

- B 기준으로 10초짜리 음성 질문 1건의 비용은 약 $0.0017입니다.
- Transcribe 가격은 AWS Price List(서울 리전, 2026-09-11 게시) 기준입니다. 초 단위로 과금하고 최소 과금 시간은 없습니다.

5.4 Amazon Transcribe의 한국어 커스텀 범위

기능	내용	한국어(ko-KR)
사용자 지정 언어 모델(CLM)	Transcribe의 파인튜닝 기능. 오디오가 아니라 분야별 텍스트를 학습시킨다	**지원 안 함.** 지원 언어는 영어(미국·영국·호주), 독일어, 스페인어(미국), 일본어, 힌디어(배치만)
사용자 지정 어휘	단어 목록 등록. 이번에 전체 어휘·위치별 어휘로 측정한 기능	지원 (배치·스트리밍)
어휘의 발음 정보 (SoundsLike·IPA)	단어가 어떻게 소리 나는지 지정	**지원 종료.** 모든 언어에서 값을 넣어도 무시된다
어휘의 표시 형식(DisplayAs)	인식된 단어를 출력할 때 적는 형태만 지정	지원. 인식 결과 자체는 바꾸지 않는다

- 한국어에서 Transcribe의 인식에 영향을 주는 커스텀 수단은 사용자 지정 어휘뿐입니다. 3.2의 위치별 어휘 결과(전각명 69.2%)가 이 수단을 적용한 결과입니다.

- 흥례문 → 흑례문 같은 남은 오인식은 Transcribe 밖에서 처리해야 합니다. 방법은 다음 두 가지이며, 둘 다 이번 측정에는 포함하지 않았습니다.
  - Transcribe 결과를 위치별 용어 목록과 대조해 비슷한 글자열을 바꾸는 후처리
  - 답변용 LLM에 현재 위치의 용어 목록을 함께 넘겨 고치게 하는 방식
- Transcribe 대신 선택지 A의 Whisper를 AWS에 직접 배포하면, 같은 위치별 사전으로 전각명 99.2%가 나옵니다(3.2).

부록

A. 산출물

경로 (**STT학습데이터/Benchmark/**)	내용
`results/summary.csv`	실행(모델 × 사전 조건 20개)별 요약
`results/per_utterance.csv`	발화별 정답·전사·CER (20개 실행 전부)
`results/term_misses.csv`	실행별로 놓친 용어, 실제로 들린 형태, 전사
`results/*.jsonl`	원본 전사·처리 시간
`data/references.csv`	녹음 ↔ 정답 대응, 포함 용어, 길이
`data/hint_terms.txt`, `data/hints_by_location.json`	전체 사전, 위치별 사전
`rename_log.csv`	녹음 파일명 정리 전후 대응표
`README.md`	코드 구성과 재현 방법

B. 이번 측정에 든 비용

- Amazon Transcribe 스트리밍 3회(사전 없음, 전체 어휘, 위치별 어휘)와 시험 실행: 약 69분, 정가 약 $0.69입니다. 측정 계정은 프리 티어 오퍼와 크레딧이 없어서 정가가 적용됩니다.
- 사용자 지정 어휘 27개(전체 1개, 위치별 26개)는 서울 리전에 남아 있으며, 보관 요금은 없습니다.
- 로컬 모델과 Apple 엔진은 측정 맥에서 실행해서 별도 비용이 없습니다.

C. 출처

- Amazon Transcribe 언어별 지원 기능: https://docs.aws.amazon.com/transcribe/latest/dg/supported-languages.html
- Amazon Transcribe 사용자 지정 어휘(표 형식): https://docs.aws.amazon.com/transcribe/latest/dg/custom-vocabulary-create-table.html
- AWS Price List, Transcribe 서울 리전(2026-09-11 게시): https://pricing.us-east-1.amazonaws.com/offers/v1.0/aws/transcribe/current/ap-northeast-2/index.json
- 모델 가중치(Hugging Face): `mlx-community/whisper-large-v3-mlx`, `mlx-community/whisper-large-v3-turbo`, `Qwen/Qwen3-ASR-1.7B-hf`, `Qwen/Qwen3-ASR-0.6B-hf`, `CohereLabs/cohere-transcribe-03-2026`