궁금(宮今) STT 벤치마크 결과 보고서 v2 — 핸드폰에서 쓰는 경로별 비교

작성 안기겸 · 2026-10-25 · 경복궁 해설 발화 녹음 180개 · 실행 환경 5종(MacBook Pro, Z6 G4, Mac mini, 맥 브라우저, iPhone)

목차

용어 풀이
1. 결론
2. 측정 조건
    2.1 데이터
    2.2 측정 장비
    2.3 지표
    2.4 사전 조건
    2.5 브라우저 실행 보정
3. 결과
    3.1 ① 폰 브라우저 안에서 실행 (WebGPU)
    3.2 ②③ 집 서버 (Z6 G4, Mac mini)
    3.3 ④ 클라우드 STT (CLOVA Speech, Amazon Transcribe)
    3.4 ⑤ 폰 자체 STT (Apple 엔진을 MacBook Pro에서 측정)
    3.5 사전 효과 (받아쓰기 사전 · 후처리 사전)
4. 판단
    4.1 사전 등록: 합니다
    4.2 파인튜닝: 모델별 판단
    4.3 권장 구성
부록
    A. 산출물 (STT학습데이터/Benchmark/)
    B. 출처

용어 풀이

보고서에 자주 나오는 말을 먼저 정리했습니다.

측정 지표

용어	뜻
STT	음성을 글자로 바꾸는 기술(Speech-to-Text)
CER (글자 오류율)	정답 100글자 중 몇 글자를 틀렸는지. 3%면 100글자 중 3글자를 틀린 것
전각명 인식률	정답 문장에 나온 전각 이름(근정전, 경회루 등)을 한 글자도 틀리지 않고 받아쓴 비율
용어 인식률	전각명과 용어집 용어(월대, 품계석 등)를 합쳐서 정확히 받아쓴 비율
발화당 대기	문장 하나를 넣은 뒤 글자가 나올 때까지 걸린 시간
p90	10번 중 9번은 이 시간 안에 끝났다는 값. 평균보다 "느린 편인 경우"를 보여 줌
RTF	처리 시간 ÷ 음성 길이. 0.1이면 10초 음성을 1초에 처리 (1보다 작으면 말하는 속도보다 빠름)
붕괴 발화	같은 말을 계속 반복하거나 사전 목록을 그대로 출력하는 등 결과가 크게 망가진 발화 (CER 50% 이상)

사전

용어	뜻
받아쓰기 사전	받아쓰는 **도중**에 모델에게 "이런 단어가 나올 수 있다"고 알려 주는 단어 목록
후처리 사전	받아쓰기가 **끝난 뒤**, 사전 단어와 비슷하게 받아쓴 단어를 사전 단어로 고치는 방식
유사도 (Jaro-Winkler)	두 단어가 얼마나 닮았는지를 0~1로 나타낸 점수. 1이면 똑같음
threshold	"이 점수 이상 닮았을 때만 바꾼다"는 기준값. 낮추면 많이 바꾸고(잘못 바꾸는 경우도 늘어남), 높이면 적게 바꿈
자모 단위 비교	글자를 초성·중성·종성으로 쪼개서 비교하는 방식. 흑례문과 흥례문은 받침 하나만 달라 점수가 높게 나옴
위치별 사전	해설 위치(근정전, 경회루 등)마다 그 위치에서 나오는 용어만 모은 사전. 앱이 사용자의 위치를 알고 그 구역 사전만 씀
그 문장을 뺀 위치별 사전	위치별 사전에서, 평가하는 그 문장에만 나오는 용어를 뺀 것. "사전에 없는 용어가 섞인" 상황을 흉내 냄
키워드 부스팅	CLOVA Speech의 받아쓰기 사전 기능. 단어 목록과 가중치(1~5)를 함께 넘기며, 가중치가 클수록 사전 단어 쪽으로 받아쓰려는 힘이 세짐
완비 / 누락	표에서 쓰는 줄임말. 완비 = 위치별 사전(사전에 용어가 다 있음), 누락 = 그 문장을 뺀 위치별 사전(사전에 없는 용어가 섞임)

모델·실행

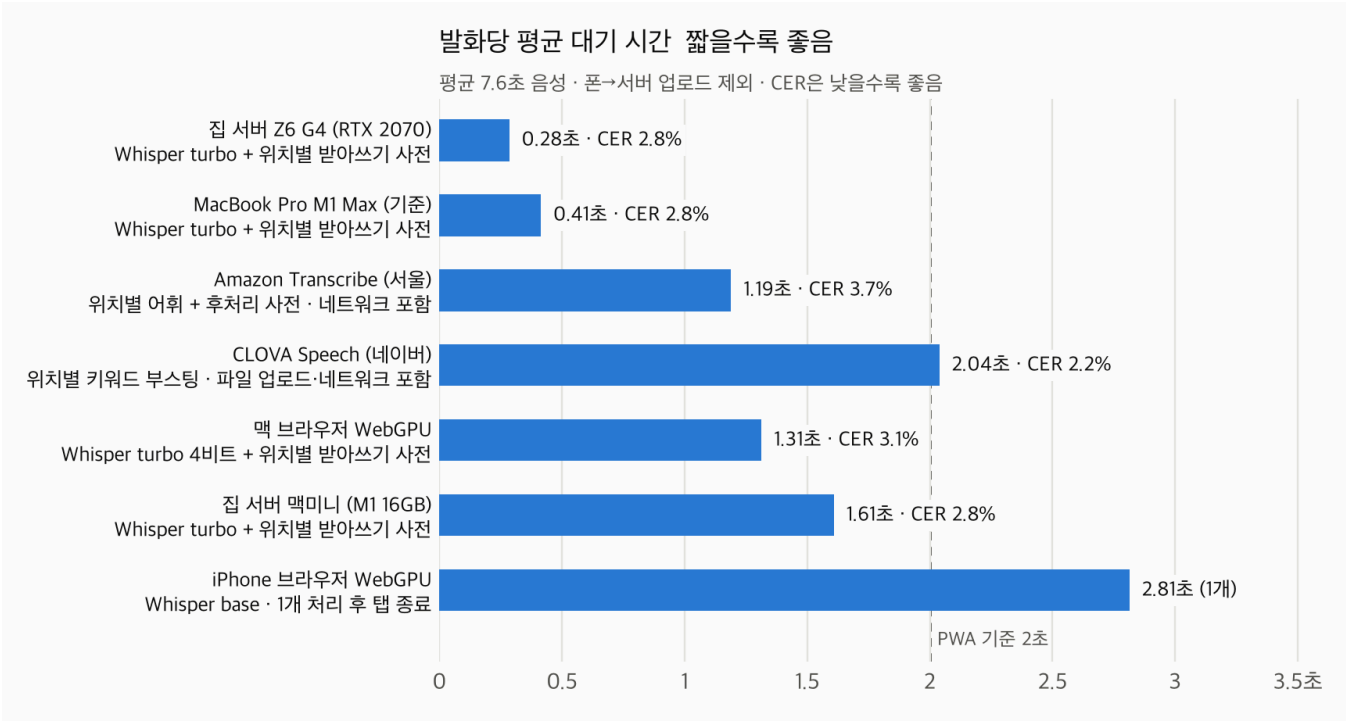
용어	뜻
파인튜닝	우리 녹음과 정답 문장으로 모델을 추가 학습시키는 것
fp16 / 4비트, 양자화	모델의 숫자 하나를 16비트 / 4비트로 저장한 판. fp16보다 적은 비트(8비트·4비트)로 줄이는 것을 양자화라고 하며, 비트가 적을수록 파일과 메모리가 작아짐
WebGPU	웹 브라우저에서 폰·PC의 GPU를 쓸 수 있게 하는 표준. 앱 설치 없이 폰 안에서 모델을 돌릴 때 필요
실행 엔진	같은 모델을 장비에 맞게 돌리는 프로그램. mlx-whisper(맥), faster-whisper(NVIDIA GPU), PyTorch(맥 GPU는 MPS, NVIDIA GPU는 CUDA), transformers.js(브라우저)
토큰	모델이 글을 처리하는 단위(단어 조각)
PWA	설치 없이 브라우저에서 앱처럼 쓰는 웹앱. 궁금 서비스의 형태

1. 결론

경로	폰에서 사용	권장 구성	CER	전각명 인식률	발화당 대기
① 폰 브라우저 안에서 실행 (WebGPU)	**iPhone 불가** · Android 미측정	없음 (가장 작은 Whisper base도 1개 처리 후 탭 종료)	—	—	2.81초 (1건)
② 집 서버 Z6 G4 (RTX 2070)	가능 (폰 녹음 → 서버 전송)	Whisper large-v3-turbo + 위치별 받아쓰기 사전	2.78% (3.73%)	99.2% (92.5%)	**0.28초**
③ 집 서버 Mac mini (M1 16GB)	가능 (폰 녹음 → 서버 전송)	Whisper large-v3-turbo + 위치별 받아쓰기 사전	2.76% (3.73%)	99.2% (92.5%)	1.61초
④ 클라우드 CLOVA Speech	가능 (폰 녹음 → 네이버 클라우드 전송)	위치별 키워드 부스팅 (가중치 1)	**2.22% (2.69%)**	96.2% (94.0%)	2.04초
④ 클라우드 Amazon Transcribe	가능 (폰 녹음 → AWS 전송)	위치별 사용자 지정 어휘 + 후처리 사전	3.73% (5.24%)	96.2% (79.0%)	1.19초
⑤ 폰 자체 STT (키보드 받아쓰기)	가능, 받아쓰는 도중에는 사전을 넣을 수 없음	Apple 받아쓰기 + 후처리 사전	9.18% (9.69%)	56.4% (54.9%)	0.93초

* CER, 발화당 대기는 낮을수록 좋음.
* 전각명 인식률은 높을수록 좋음.
* 괄호 밖은 사전에 그 문장의 용어가 모두 들어 있을 때(위치별 사전), 괄호 안은 사전에 없는 용어가 섞일 때(그 문장을 뺀 위치별 사전)의 값입니다(2.4). 괄호 안은 MacBook Pro에서 잰 값이고, Amazon Transcribe의 괄호 안은 어휘 없이 후처리 사전만 쓴 값입니다.
* 발화당 대기: ②③은 서버 처리 시간만이고 폰 → 서버 업로드 시간은 빠져 있습니다. ④는 클라우드까지의 네트워크 왕복을 포함합니다(CLOVA Speech는 녹음 파일 업로드도 포함). ⑤는 같은 계열 엔진을 맥에서 잰 값입니다.

- 이번 수치는 **휴대폰으로 낭독한 녹음**(조용한 실내로 추정) 기준입니다.
- **폰은 녹음만 하고, 인식은 서버에서 합니다.** ② Z6 G4 + Whisper large-v3-turbo + 위치별 받아쓰기 사전을 권장합니다. 전각명 인식률 99.2%인 구성 중 가장 빠릅니다.
- **같은 서버에서 Qwen3-ASR 1.7B + 붕괴 방지를 쓰면 CER이 Whisper turbo보다 낮습니다.** CER 2.55%로 turbo(2.76%, 둘 다 MacBook Pro 기준)보다 낮고, 사전에 없는 용어가 섞이면 2.86%로 turbo(3.73%)보다 훨씬 낮습니다. 대신 Z6 G4에서 약 3배 느립니다(0.93초 대 0.28초, 둘 다 2초 이내). 두 모델의 선택 기준은 4.3에 정리했습니다.
- **CER이 가장 낮은 것은 클라우드 CLOVA Speech입니다.** 위치별 키워드 부스팅으로 CER 2.22%, 사전에 없는 용어가 섞여도 2.69%로 두 조건 모두 가장 낮고, 사전 없이도 3.20%입니다. 대신 녹음 파일을 한 번에 보내는 방식으로 쟀을 때 대기가 평균 2.04초로 2초 기준을 조금 넘었고, 요청 1건에 5원이 듭니다.
- **폰 브라우저 안에서 직접 돌리는 방식(①)은 iPhone에서 쓸 수 없습니다.** 후보 모델(0.5GB 이상)은 모델을 올리는 단계에서 Safari 탭이 강제 종료됐고, 가장 작은 Whisper base(146MB)도 1개를 처리한 뒤 종료됐습니다.
- **같은 모델이면 장비·실행 엔진이 달라도 CER이 거의 같습니다**(차이 최대 0.31%p). 장비가 바꾸는 것은 주로 속도입니다.
- **사전은 넣습니다.** 앱에 위치별 용어 목록을 넣어 두고, Whisper·Qwen3-ASR·CLOVA Speech에는 받아쓰기 사전(CLOVA는 키워드 부스팅)으로, 받아쓰기 사전이 없거나 약한 모델에는 후처리 사전으로 씁니다(3.5).
  - CLOVA Speech: 전각명 87.2%(사전 없음) → 96.2%(위치별 키워드 부스팅)
  - Amazon Transcribe: 전각명 56.4%(사전 없음) → 69.2%(위치별 어휘) → 96.2%(어휘 + 후처리 사전)
  - Cohere Transcribe: 전각명 48.1%(사전 없음) → 84.2%(후처리 사전)
- **사전에 없는 용어는 놓치기 쉽습니다.** 그 문장을 뺀 사전으로 재면 Whisper turbo의 전각명 인식률이 99.2%에서 92.5%로 내려가고, 놓친 용어 61건 중 53건이 사전에 없던 용어였습니다. 그래서 위치별 사전은 그 구역 해설에 나오는 용어를 빠짐없이 담아야 합니다.
- **파인튜닝은 권장 구성(Whisper, Qwen3-ASR)에서는 하지 않습니다.** Whisper·Qwen3-ASR·Cohere는 가중치가 공개돼 있어 파인튜닝이 가능하고, Amazon Transcribe(한국어)·CLOVA Speech·Apple 엔진은 불가능합니다. 모델별 판단은 4.2에 정리했습니다.


발화당 평균 대기 시간 짧을수록 좋음
평균 7.6초 음성 · 폰→서버 업로드 제외 · CER은 낮을수록 좋음
집 서버 Z6 G4 (RTX 2070)
Whisper turbo + 위치별 받아쓰기 사전
0.28초 · CER 2.8%
MacBook Pro M1 Max (기준)
Whisper turbo + 위치별 받아쓰기 사전
0.41초 · CER 2.8%
Amazon Transcribe (서울)
위치별 어휘 + 후처리 사전 · 네트워크 포함
1.19초 · CER 3.7%
CLOVA Speech (네이버)
위치별 키워드 부스팅 · 파일 업로드·네트워크 포함
2.04초 · CER 2.2%
맥 브라우저 WebGPU
Whisper turbo 4비트 + 위치별 받아쓰기 사전
1.31초 · CER 3.1%
집 서버 맥미니 (M1 16GB)
Whisper turbo + 위치별 받아쓰기 사전
1.61초 · CER 2.8%
iPhone 브라우저 WebGPU
Whisper base · 1개 처리 후 탭 종료
2.81초 (1개)
PWA 기준 2초
0
0.5
1
1.5
2
2.5
3
3.5초

2. 측정 조건

2.1 데이터

항목	값
발화문	`경복궁_STT_발화문_300.xlsx` 중 녹음된 U0001~U0180 (180개, 해설 위치 26곳)
녹음	5명이 발화문을 소리 내어 읽어 녹음(낭독). 조용한 실내에서 휴대폰으로 녹음한 것으로 추정 (m4a, 48kHz 모노)
길이	총 1,363.9초, 발화당 4.2~12.8초 (평균 7.58초)
평가 용어	정답 문장에 나온 용어집 용어 314건 + 전각명 133건 = 447건
녹음 대응 보정	`U0061~U0069` 파일에는 U0060~U0068 문장이 녹음되어 있어 실제 문장으로 비교. 그래서 U0060 문장은 두 번 녹음됐고 U0069 문장은 녹음이 없음(녹음 180개 = 문장 179종)

2.2 측정 장비

장비	사양	실행 엔진
MacBook Pro (기준)	M1 Max, 32GB, macOS 27.0.1	Whisper: mlx-whisper / Qwen·Cohere: PyTorch MPS, 모두 fp16
Z6 G4 (집)	Xeon Gold 5122(4코어 8스레드), RAM 64GB, RTX 2070 8GB, Ubuntu 26.04	Whisper: faster-whisper 1.2.1(CTranslate2 4.8.3) / Qwen·Cohere: PyTorch 2.14 CUDA 13, 모두 fp16
Mac mini (집)	M1, 16GB, macOS 26.5.2	MacBook Pro와 같음. 측정 중에 다른 프로세스가 돌고 있었음(부하 평균 약 2)
맥 브라우저	MacBook Pro의 Chromium 152 계열 브라우저, WebGPU(Metal)	transformers.js 4.3.1, onnx-community ONNX 모델
iPhone	Safari 27.0.1, WebGPU, shader-f16 지원, GPU 버퍼 최대 1GB	맥 브라우저와 같은 측정 페이지

2.3 지표

지표	계산 방법	예
CER	틀린 글자 수(빠짐·더해짐·바뀜) ÷ 정답 글자 수. 180개를 합쳐서 계산. 공백·문장부호는 빼고, 숫자는 양쪽 모두 한자어 읽기로 바꿔 비교	정답 "근정전 월대"를 "금정전 월대"로 받아쓰면 5글자 중 1글자가 틀려 CER 20%
전각명 인식률 / 용어 인식률	정답에 나온 전각명(133건) / 용어집 용어와 전각명(447건) 중, 받아쓴 결과에 정답과 똑같은 표기가 나온 비율	"흥례문"을 "흑례문"으로 받아쓰면 한 글자 차이여도 놓친 것으로 셈
발화당 대기	발화 하나를 넣고 글자를 받기까지 걸린 시간. 모델을 불러오는 시간은 빼고, 1회 미리 돌려 본 뒤(워밍업) 측정	—
RTF	처리 시간 합 ÷ 음성 길이 합	7.6초 음성을 0.3초에 처리하면 RTF 0.04
붕괴 발화	CER이 50% 이상인 발화 수	"경성전 경성전 경성전 …" 반복 출력

* CER, 발화당 대기, RTF, 붕괴 발화는 낮을수록 좋음. RTF가 1보다 작으면 실시간보다 빠름.
* 전각명 인식률, 용어 인식률은 높을수록 좋음.

- **PWA 기준**: 말을 마친 뒤 결과까지 2초 이내.
- **집 서버의 대기 시간에는 폰에서 서버로 녹음을 보내는 시간이 빠져 있습니다.** 7.6초 음성은 WAV(16kHz·16bit)로 약 243KB, Opus 24kbps로 약 23KB입니다.
- **Amazon Transcribe의 대기 시간**에는 서울 리전까지의 연결·네트워크 왕복이 포함됩니다.

- **CLOVA Speech의 대기 시간**에는 녹음 파일(WAV) 업로드와 네트워크 왕복이 포함됩니다. 스트리밍이 아니라 녹음이 끝난 파일을 한 번에 보내는 방식(장문 인식 API, sync)입니다.

2.4 사전 조건

사전은 두 단계에서 씁니다.

구분	쓰는 시점	방법	조절 값
받아쓰기 사전	STT가 받아쓰는 **도중**	모델에 단어 목록이나 문장을 힌트로 넘김 (모델별 방법은 아래 표)	대부분 없음. CLOVA Speech만 키워드 부스팅 가중치(1~5)가 있어 1·3·5를 측정
후처리 사전 (유사도 threshold 방식)	받아쓰기가 **끝난 뒤**	받아쓴 단어와 사전 단어의 유사도(Jaro-Winkler, 0~1)가 threshold 이상이면 사전 단어로 바꿈	threshold 0.70~0.95 (0.05 간격)

모델	받아쓰기 사전을 넘기는 방법
Whisper	`initial_prompt`(앞 문맥으로 넣는 문장) — "경복궁 해설입니다. 근정전, 월대, …" (최대 223토큰)
Qwen3-ASR	시스템 프롬프트(모델에 주는 지시문) — "경복궁 해설 용어: 근정전, 월대, …"
Amazon Transcribe	사용자 지정 어휘 — 단어 목록
Apple 엔진	문맥 문자열(`contextualStrings`) — 단어 목록
CLOVA Speech	키워드 부스팅 — 단어 목록 + 가중치(1~5), 요청마다 넘김
Cohere Transcribe	방법 없음 (사전 입력 기능 없음)

- **Qwen3-ASR 붕괴 방지**: Qwen3-ASR은 가끔 받아쓰기 대신 사전 목록("경복궁 해설 용어: …")을 그대로 출력합니다. 출력에 "해설 용어"가 들어 있으면 사전 없이 한 번 더 받아쓰는 조건도 측정했습니다(3.5).

받아쓰기 사전과 후처리 사전은 같은 사전 목록을 씁니다.

사전	내용	평가 문장의 용어가 사전에 있는 비율
없음	사전을 쓰지 않음	—
위치별 사전	해설 위치마다 그 위치 발화문(엑셀 300개 기준)에 나온 전각명·용어를 모은 목록. 녹음된 26곳 기준 위치당 5~26개	전각명 133/133, 용어 314/314 (모두 있음)
그 문장을 뺀 위치별 사전	위치별 사전을 만들 때 평가하는 그 문장만 빼고 만든 목록. 사전에 없는 용어가 섞이는 상황을 흉내 냄	전각명 105/133 (79%), 용어 103/314 (33%)
전체 사전	용어집과 전각명을 합친 336개 표기	모두 있음

- **위치별 사전은 평가 문장에서 직접 뽑았습니다.** 그래서 위치별 사전의 결과는 "앱 사전에 사용자가 말한 용어가 모두 들어 있을 때"의 값(가장 좋은 경우)이고, 그 문장을 뺀 위치별 사전의 결과는 "사전에 없는 용어가 많이 섞일 때"의 값(나쁜 경우)입니다. 실제 앱은 이 둘 사이에 있습니다.
- **앱이 해설 위치 26곳 중 어디인지 정확히 안다고 가정했습니다.** 근정전·근정전 내부·근정전 조정처럼 붙어 있는 위치는 GPS로 나누기 어려워, 실제 앱에서는 이런 위치의 사전을 합쳐 써야 합니다.
- 전체 사전은 받아쓰기 사전으로 Qwen3-ASR·Amazon Transcribe·Apple 엔진에서만 쟀습니다. Whisper는 223토큰 제한 때문에 336개를 다 넣을 수 없습니다.

후처리 사전의 세부 규칙

- **바꾸는 기준**: threshold 이상인 사전 단어 중 가장 비슷한 것으로 바꿉니다. 여러 어절로 된 용어는 어절마다 모두 threshold 이상이어야 바꿉니다.
- **한국어 보정**:

    - 어절 끝의 조사·어미를 떼기 위해, 어절 앞부분(사전 단어와 같은 길이)만 비교하고 그 부분만 바꿉니다. 예: "홍해문을" → "홍예문을"
    - 1음절 용어(칸 등)는 쓰지 않습니다.
- **유사도 단위**: 음절 단위와 자모 단위(초성·중성·종성으로 쪼개 비교)를 모두 쟀습니다.
- **측정 방식**:
    - 받아 둔 전사 결과(MacBook Pro, 받아쓰기 조건 23개)에 사전 3종 × 유사도 단위 2종 × threshold 6개를 적용했습니다.
    - 주요 구성 9개는 녹음 → STT → 후처리를 처음부터 다시 돌려 확인했습니다(실시간 재측정, 3.5).
    - threshold와 "모델별 권장 사전 조합"은 이 180개 발화로 고르고 같은 180개로 잰 값입니다.

2.5 브라우저 실행 보정

transformers.js에는 Python Whisper에 있는 두 기능이 없어서, 측정 페이지에서 직접 구현했습니다.

- **받아쓰기 사전 입력**: Whisper의 `initial_prompt`(`prompt_ids`)가 없어서, 사전 문장을 디코더 시작 토큰(`decoder_input_ids`)으로 직접 넘겼습니다. 이 방식으로 사전이 실제로 반영되는 것을 확인했습니다.
- **반복 방지**: Python 쪽(mlx-whisper·faster-whisper)에는 반복 출력을 감지해 다시 디코딩하는 기능이 있는데, transformers.js에는 없습니다. 그래서 두 가지 장치를 넣었습니다.
    - 출력 길이를 음성 길이에 비례해 제한합니다. 실제 발화는 초당 최대 6토큰이어서, 상한을 초당 12토큰 + 10으로 잡았습니다.
    - 출력이 이 상한에 닿거나 같은 단어가 4번 이상 반복되면, 사전 없이 한 번 더 디코딩합니다. 이 재디코딩 시간도 대기 시간에 포함했습니다.

3. 결과

3.1~3.4는 경로별 결과이고, 표의 "사전"은 받아쓰기 사전입니다. 후처리 사전의 결과는 3.5에 모았습니다.

3.1 ① 폰 브라우저 안에서 실행 (WebGPU)

브라우저 실행 지원과 모델 크기

모델	브라우저 실행	가장 작은 버전 크기
Whisper large-v3-turbo	transformers.js 지원	563MB (4비트 q4f16)
Whisper large-v3	transformers.js 지원	980MB (q4f16)
Cohere Transcribe	transformers.js 지원 (v4.0.0부터)	1,535MB (q4f16)
Qwen3-ASR 1.7B·0.6B	**transformers.js 미지원** (커뮤니티 포트만 있음)	—
(참고) Whisper small	transformers.js 지원	485MB (fp16)
(참고) Whisper base	transformers.js 지원	146MB (fp16)

iPhone Safari 실측

시도	크기	결과
Whisper large-v3-turbo 4비트	563MB	디코더(193MB)를 받은 뒤 인코더(370MB)를 불러오는 중 탭 강제 종료 (2회)
같은 모델, 브라우저 캐시 저장 끔	563MB	인코더를 받는 도중 탭 강제 종료
Whisper small fp16	485MB	두 파일을 다 받은 뒤 GPU에 올리는 단계에서 탭 강제 종료
Whisper base fp16	146MB	모델 준비 14.2초, U0001(6.7초 음성)을 **2.81초(RTF 0.42)** 에 처리한 뒤 다음 발화에서 탭 강제 종료

- 탭 강제 종료는 Safari의 "문제가 반복적으로 발생했습니다" 화면으로 나타났습니다. 탭이 메모리 한도를 넘었을 때 나오는 화면입니다.
- iPhone Safari가 웹사이트 하나에 허용하는 메모리는 약 1.5~1.88GB로 보고되어 있습니다(부록 B의 WebKit 버그 268816, 324370).
- 브라우저는 모델 파일을 받아서 GPU에 올리기까지 여러 벌의 사본을 메모리에 두기 때문에, 파일 크기보다 훨씬 많은 메모리를 씁니다.
- iPhone에서 base로 U0001을 처리한 시간(2.81초)은, 같은 발화를 맥 브라우저에서 처리한 시간(0.85초)의 약 3.3배였습니다.
- Android Chrome은 측정하지 않았습니다. WebGPU는 Chrome 121 이상, Android 12 이상에서 일부 GPU만 지원합니다.

맥 브라우저(M1 Max) 측정 — 같은 페이지, 모델 크기별 정확도

모델·정밀도	받아쓰기 사전	반복 방지	CER	용어	전각명	붕괴	발화당 대기
Whisper turbo 4비트	없음	없음	5.32%	71.4%	63.2%	0	1.52초
Whisper turbo 4비트	위치별	없음	7.45%	94.4%	99.2%	1	1.36초
Whisper turbo 4비트	**위치별**	**있음**	**3.10%**	**94.4%**	**98.5%**	**0**	**1.31초**
Whisper turbo fp16	위치별	없음	2.79%	95.3%	99.2%	0	1.33초
Whisper small fp16	위치별	있음	5.44%	96.2%	98.5%	0	1.20초
Whisper base fp16	위치별	있음	10.61%	90.6%	89.5%	0	0.71초

* CER, 붕괴, 발화당 대기는 낮을수록 좋음.
* 용어·전각명 인식률은 높을수록 좋음.

- 같은 측정 페이지를 맥 브라우저에서 연 결과입니다. 한 줄 요약: 브라우저에서도 turbo는 정확하지만, iPhone에 올라가는 크기(base)로 줄이면 CER이 10%를 넘습니다.
- 4비트로 줄여도 정확도 손실은 작습니다. 사전 없는 turbo가 4비트에서 5.32%, MLX fp16에서 5.12%였습니다.
- 반복 방지가 없으면 사전 단어("경성전")를 끝없이 반복하는 붕괴가 1건 나왔습니다. 반복 방지를 넣은 뒤에는 재디코딩 1건으로 붕괴가 사라졌습니다.
- 모델이 작을수록 받아쓰기가 거칠어집니다. iPhone에서 그나마 올라가는 base는 위치별 사전을 넣어도 CER 10.6%입니다.

3.2 ②③ 집 서버 (Z6 G4, Mac mini)

한 줄 요약: 같은 모델이면 정확도는 장비가 달라도 거의 같고, 속도는 Z6 G4가 가장 빠릅니다(Whisper 기준 Mac mini보다 약 5~6배).

정밀도: 집 서버의 모든 모델은 양자화(8비트·4비트) 없이 fp16으로 돌렸습니다.

- Z6 G4: Whisper는 faster-whisper `float16`, Qwen3-ASR·Cohere는 PyTorch CUDA `float16`
- Mac mini: Whisper는 mlx-whisper `float16`, Qwen3-ASR·Cohere는 PyTorch MPS `float16`
- 양자화는 브라우저 측정(3.1)에서만 했습니다(Whisper turbo 4비트). 집 서버에서 양자화한 모델의 속도·정확도는 이번 표에 없습니다.

모델	받아쓰기 사전	CER (Z6 G4 / Mac mini)	전각명	붕괴 (Z6 G4 / Mac mini)	Z6 G4 대기 (평균 / p90)	Mac mini 대기 (평균 / p90)	참고: MacBook Pro 평균
Whisper turbo	**위치별**	**2.78% / 2.76%**	**99.2%**	**0 / 0**	**0.28 / 0.29초**	**1.61 / 1.66초**	0.41초
Whisper turbo	없음	5.09% / 5.12%	66.2%	0 / 0	0.27 / 0.29초	1.54 / 1.62초	0.40초
Whisper large-v3	위치별	2.45% / 2.43%	99.2%	0 / 0	0.55 / 0.63초	2.95 / 3.37초	0.78초
Whisper large-v3	없음	5.98% / 5.67%	62.4%	2 / 1	0.53 / 0.62초	2.85 / 3.25초	0.77초
Qwen3-ASR 1.7B	위치별	3.33% / 3.33%	94.7%	1 / 1	0.93 / 1.23초	3.00 / 3.88초	0.70초
Qwen3-ASR 1.7B	없음	4.17% / 4.17%	72.2%	0 / 0	0.92 / 1.22초	2.83 / 3.71초	0.67초
Qwen3-ASR 0.6B	위치별	4.01% / 4.01%	92.5%	0 / 0	0.89 / 1.22초	1.33 / 1.76초	0.43초
Qwen3-ASR 0.6B	없음	6.35% / 6.42%	58.6%	0 / 0	0.89 / 1.20초	1.24 / 1.62초	0.43초
Cohere Transcribe	없음 (사전 기능 없음)	8.95% / 9.05%	48.1%	0 / 0	0.22 / 0.27초	0.94 / 1.22초	0.42초

* CER, 붕괴, 대기 시간은 낮을수록 좋음.
* 전각명 인식률은 높을수록 좋음.

- 전각명 인식률은 Z6 G4 기준입니다. Mac mini는 Qwen3-ASR 0.6B 사전 없음(57.1%)만 1.5%p 낮았고, 나머지는 같았습니다.
- **장비마다 실행 엔진이 다릅니다**(Z6 G4의 Whisper는 faster-whisper, 맥은 mlx-whisper). Whisper large-v3 사전 없음의 CER 차이(5.98% / 5.67%)는 Z6 G4에서만 붕괴가 1건 더 나왔기 때문입니다. 문장 끝에 "이 영상은 제작지원으로 제작되었습니다"라는 엉뚱한 문장이 붙었습니다. 같은 문장을 반복한 붕괴 1건은 세 장비 공통입니다.
- Qwen3-ASR 1.7B + 위치별 사전의 붕괴 1건은 세 장비 모두 같은 발화(U0073)에서 사전 목록을 그대로 출력한 것입니다(붕괴 방지 결과는 3.5).

- **Z6 G4**는 Whisper와 Cohere가 가장 빨랐습니다. Whisper turbo + 위치별 사전이 RTF 0.038로, 7.6초 음성을 0.3초 안에 처리합니다.
  - 다만 180개 중 1개(U0066)는 2.27초가 걸렸습니다. 나머지 179개는 모두 0.5초 이내였습니다. 같은 발화가 MacBook Pro에서 2.38초, Mac mini에서 9.76초, 실시간 재측정에서 3.10초였고, 사전 없음·그 문장을 뺀 사전 조건에서는 0.4초대였습니다.
  - Qwen3-ASR은 Z6 G4에서 MacBook Pro보다 느렸습니다(1.7B 기준 0.92초 대 0.67초).
- **Mac mini**는 측정 중 다른 프로세스가 돌고 있던 상태(부하 평균 약 2)의 값이라, 비어 있을 때보다 느리게 나왔을 수 있습니다. 이 상태에서 평균과 p90이 모두 2초 안에 든 모델은 Whisper turbo, Qwen3-ASR 0.6B, Cohere Transcribe입니다.

3.3 ④ 클라우드 STT (CLOVA Speech, Amazon Transcribe)

CLOVA Speech (네이버 클라우드)

한 줄 요약: 사전 없는 조건끼리 비교하면 다른 모델보다 정확하고, 위치별 키워드 부스팅(가중치 1)을 넣으면 CER 2.22%로 이번 측정에서 가장 낮습니다. 대기는 평균 2.04초입니다.

키워드 부스팅	CER	용어	전각명	붕괴	발화당 대기 (평균 / p90)
없음	3.20%	86.6%	87.2%	0	1.95 / 2.07초
위치별 사전, 가중치 1	**2.22%**	**96.9%**	**96.2%**	**0**	**2.04 / 2.27초**
위치별 사전, 가중치 3	7.39%	94.9%	94.7%	8	2.21 / 2.39초
위치별 사전, 가중치 5	9.16%	93.5%	94.0%	11	2.44 / 2.68초
그 문장을 뺀 위치별 사전, 가중치 1	2.69%	92.4%	94.0%	0	2.05 / 2.48초

* CER, 붕괴, 발화당 대기는 낮을수록 좋음.
* 용어·전각명 인식률은 높을수록 좋음.

- **측정 방식**: 장문 인식 API(sync)에 녹음 파일(16kHz WAV)을 한 번에 올리고, 결과를 받을 때까지의 시간을 쟀습니다. 키워드 부스팅 단어는 요청마다 넘길 수 있어서, 위치별 사전과 그 문장을 뺀 사전을 모두 쟀습니다. 부스팅에는 1음절 단어를 넣을 수 없어 빼고 넣었습니다(최대 1,000개). 단문 인식 API는 부스팅 단어가 3글자 이상이어야 해서(월대·드므 등을 넣을 수 없음) 쓰지 않았습니다.
- **가중치는 1이 가장 좋았습니다.** 3·5로 올리면 결과가 빈 문자열로 돌아오는 발화가 8개, 11개 생겨 CER이 크게 나빠졌습니다. 가중치도 이 180개 발화로 고른 값입니다.
- **대기 시간은 음성 길이와 거의 상관없이 약 2초입니다**(최소 1.66초). 가중치 1 조건에서 180개 중 86개가 2초를 넘었습니다. CLOVA Speech는 실시간 스트리밍 인식 API(gRPC)도 제공하지만, 이번에는 재지 않았습니다.
- **요금**: 장문 인식 Basic 플랜은 15초당 5원이고 과금 단위가 15초라서, 10초 질문 1건도 5원입니다. 요금표에 키워드 부스팅 항목은 따로 없습니다. Free 플랜은 월 20분까지 무료입니다(부록 B).
- **파인튜닝은 할 수 없습니다.** 콘솔 빌더 메뉴는 데모, 키워드 부스팅, 인식 결과 보정, 설정이고, 우리 데이터로 학습시키는 기능은 없습니다.

Amazon Transcribe

사전	CER	용어	전각명	발화당 대기 (평균 / p90)
없음	5.78%	68.5%	56.4%	1.09 / 1.50초
전체 사용자 지정 어휘 (336개)	5.09%	75.8%	63.9%	1.20 / 1.59초
위치별 사용자 지정 어휘 (위치마다 어휘 1개, 5~26단어)	4.60%	79.6%	69.2%	1.19 / 1.59초
위치별 어휘 + 후처리 사전 (자모 유사도 0.85)	**3.73%**	**94.2%**	**96.2%**	**1.19 / 1.59초**

* CER, 발화당 대기는 낮을수록 좋음.
* 용어·전각명 인식률은 높을수록 좋음.

- 서울 리전 스트리밍 요금은 초당 $0.0001667(분당 약 $0.01)이고, 1초 단위로 청구되며 최소 요금이 없습니다. 사용자 지정 어휘는 추가 요금이 없습니다. 10초 질문 1건은 약 $0.0017입니다(부록 B).
- 한국어는 사용자 지정 언어 모델(Transcribe의 파인튜닝)을 지원하지 않습니다. 어휘의 발음 정보(SoundsLike·IPA) 입력도 지원이 종료됐습니다. 그래서 위치별 어휘가 Amazon Transcribe **서비스 안에서** 쓸 수 있는 커스텀의 전부입니다.
- 어휘를 넣은 뒤에도 흥례문 → 흑례문, 신무문 → 신문문처럼 틀린 전각명은, 받아쓰기 뒤의 후처리 사전으로 대부분 바로잡혔습니다(3.5).

3.4 ⑤ 폰 자체 STT (Apple 엔진을 MacBook Pro에서 측정)

엔진	PWA에서 쓰는 방법	받아쓰기 사전	CER	용어	전각명
Apple 받아쓰기 (DictationTranscriber, 키보드 받아쓰기 계열)	입력창에서 키보드 받아쓰기	앱이 넘길 수 없음	9.98%	55.0%	48.1%
Apple SpeechTranscriber	**쓸 수 없음** (네이티브 앱 전용, 브라우저·JavaScript 노출 없음)	넣어도 반영 안 됨	6.11%	66.0%	58.6%

* CER은 낮을수록 좋음.
* 용어·전각명 인식률은 높을수록 좋음.

- iPhone에서 직접 잰 값이 아니라, Apple이 키보드 받아쓰기 계열로 제공하는 엔진(DictationTranscriber)을 맥에서 잰 값입니다.
- PWA에서 쓸 수 있는 폰 자체 경로는 키보드 받아쓰기와 Safari Web Speech API입니다. Web Speech API는 예전 엔진(SFSpeechRecognizer 계열)을 쓰며, 이번 측정에는 포함하지 않았습니다.
- 키보드 받아쓰기 결과도 앱이 받은 뒤 후처리 사전으로 고칠 수는 있습니다. 하지만 Apple 받아쓰기는 후처리 뒤에도 CER 9.18%, 전각명 56.4%에 그쳤습니다(3.5).

3.5 사전 효과 (받아쓰기 사전 · 후처리 사전)

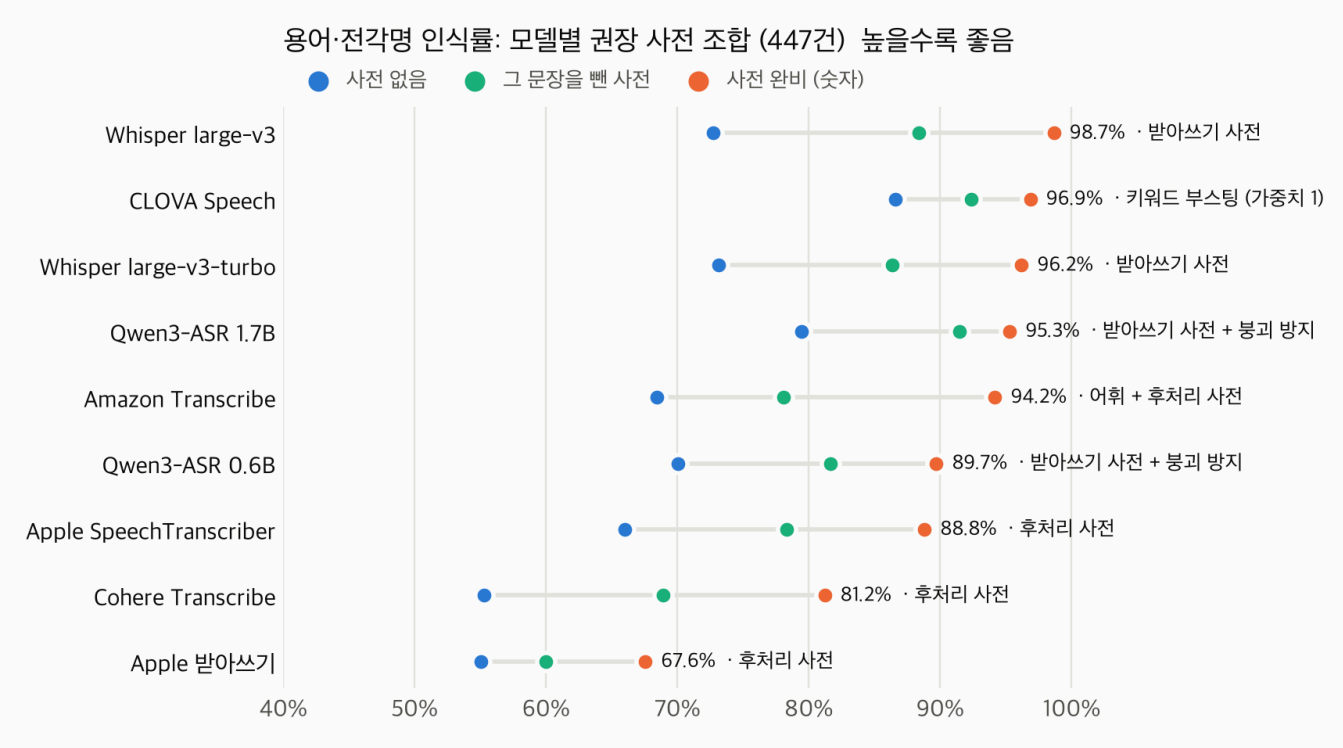
모델별 권장 사전 조합

권장 조합은 이렇게 정했습니다. 받아쓰기 사전이 잘 듣는 모델(Whisper, Qwen3-ASR, CLOVA Speech)은 받아쓰기 사전만 쓰고, 받아쓰기 사전이 없거나 약한 모델(Amazon Transcribe, Cohere Transcribe, Apple 엔진)은 후처리 사전을 더합니다. 이렇게 고른 이유는 아래 "후처리 사전: 모델별 효과"에 있습니다.

한 줄 요약: CER은 두 조건 모두 CLOVA Speech가 가장 낮습니다. 사전에 용어가 다 들어 있으면 Whisper가 전각명을 가장 잘 받아쓰고, 사전에 없는 용어가 섞이면 CLOVA Speech와 Qwen3-ASR 1.7B가 강합니다.

모델	권장 사전 조합	CER (완비 / 누락)	전각명 (완비 / 누락)	용어 (완비 / 누락)	놓친 용어 447건 중 (완비 / 누락)
CLOVA Speech	**키워드 부스팅 (가중치 1)**	**2.22% / 2.69%**	96.2% / 94.0%	96.9% / 92.4%	14 / 34
Whisper large-v3	받아쓰기 사전	2.43% / 3.38%	99.2% / 90.2%	98.7% / 88.4%	6 / 52
Whisper large-v3-turbo	받아쓰기 사전	2.76% / 3.73%	99.2% / 92.5%	96.2% / 86.4%	17 / 61
Qwen3-ASR 1.7B	받아쓰기 사전 + 붕괴 방지	2.55% / 2.86%	94.0% / 91.7%	95.3% / 91.5%	21 / 38
Qwen3-ASR 0.6B	받아쓰기 사전 + 붕괴 방지	3.94% / 4.99%	92.5% / 85.7%	89.7% / 81.7%	46 / 82
Amazon Transcribe	어휘 + 후처리 사전	3.73% / 5.24%	96.2% / 79.0%	94.2% / 78.1%	26 / 98
Apple SpeechTranscriber	후처리 사전	4.45% / 5.25%	94.0% / 83.5%	88.8% / 78.3%	50 / 97
Cohere Transcribe	후처리 사전	7.06% / 7.98%	84.2% / 74.4%	81.2% / 68.9%	84 / 139
Apple 받아쓰기	후처리 사전	9.18% / 9.69%	56.4% / 54.9%	67.6% / 60.0%	145 / 179

* CER, 놓친 용어는 낮을수록 좋음.
* 전각명·용어 인식률은 높을수록 좋음.
* 완비 = 위치별 사전, 누락 = 그 문장을 뺀 위치별 사전. 후처리 사전은 자모 단위·threshold 0.85. 모두 MacBook Pro에서 같은 180개 발화로 잰 값입니다.
* Amazon Transcribe의 누락 값은 어휘 없이 후처리 사전만 쓴 값입니다. 어휘까지 그 문장을 빼려면 발화마다 어휘를 따로 만들어야 해서 측정하지 않았습니다.
* Apple 받아쓰기는 PWA에서 받아쓰는 도중 사전을 넣을 수 없어 후처리 사전만 씁니다. 맥에서 문맥 문자열까지 넣으면 CER 8.13%입니다.



- **Whisper는 사전에 있는 용어에 강합니다.** 사전 완비 때 전각명 99.2%이지만, 그 문장을 뺀 사전에서는 90~92%로 내려갑니다. turbo가 놓친 용어 61건 중 53건이 사전에 없던 용어였습니다.
- **CLOVA Speech와 Qwen3-ASR 1.7B는 사전에 없는 용어에도 강합니다.** 사전 조건이 바뀌어도 CER 변화가 작고(CLOVA 2.22% → 2.69%, Qwen 2.55% → 2.86%), 사전에 없던 용어 239건 중 CLOVA는 212건, Qwen은 211건을 맞혀 Whisper turbo(186건)보다 많았습니다.
- 사전이 없으면 용어 인식률이 CLOVA Speech는 86.6%, 나머지 모델은 55~79%에 그칩니다(파란 점).

Qwen3-ASR 붕괴 방지

Qwen3-ASR은 가끔 받아쓰기 대신 받아쓰기 사전(시스템 프롬프트)을 그대로 출력합니다. 출력에 "해설 용어"가 들어 있으면 사전 없이 한 번 더 받아쓰도록 했습니다.

조건	CER	전각명	붕괴	다시 받아쓴 발화	발화당 대기 (평균 / 최대)
Qwen3-ASR 1.7B + 위치별 사전	3.38%	94.7%	1	—	0.70 / 1.56초
Qwen3-ASR 1.7B + 위치별 사전 + 붕괴 방지	**2.55%**	94.0%	0	1	0.72 / 2.52초
Qwen3-ASR 1.7B + 그 문장을 뺀 사전 + 붕괴 방지	2.86%	91.7%	0	2	0.71 / 2.37초
Qwen3-ASR 0.6B + 위치별 사전 + 붕괴 방지	3.94%	92.5%	0	0	0.42 / 0.72초

* CER, 붕괴, 다시 받아쓴 발화, 대기 시간은 낮을수록 좋음.
* 전각명 인식률은 높을수록 좋음.

- 1.7B는 U0073에서 사전 목록을 출력했고(이 발화 CER 115%), 붕괴 방지로 다시 받아쓰자 전체 CER이 3.38%에서 2.55%로 내려갔습니다. 이 1건이 CER을 0.8%p 올리고 있었습니다.
- 다시 받아쓴 발화(180개 중 1~2개)는 받아쓰기를 두 번 하므로 대기가 늘었습니다(최대 2.52초).
- 붕괴 방지를 넣으면 1.7B도 받아쓰기 사전(2.55%)이 후처리 사전만 쓸 때(3.20%)보다 좋습니다.

후처리 사전: 유사도 단위·사전 종류·threshold별 결과

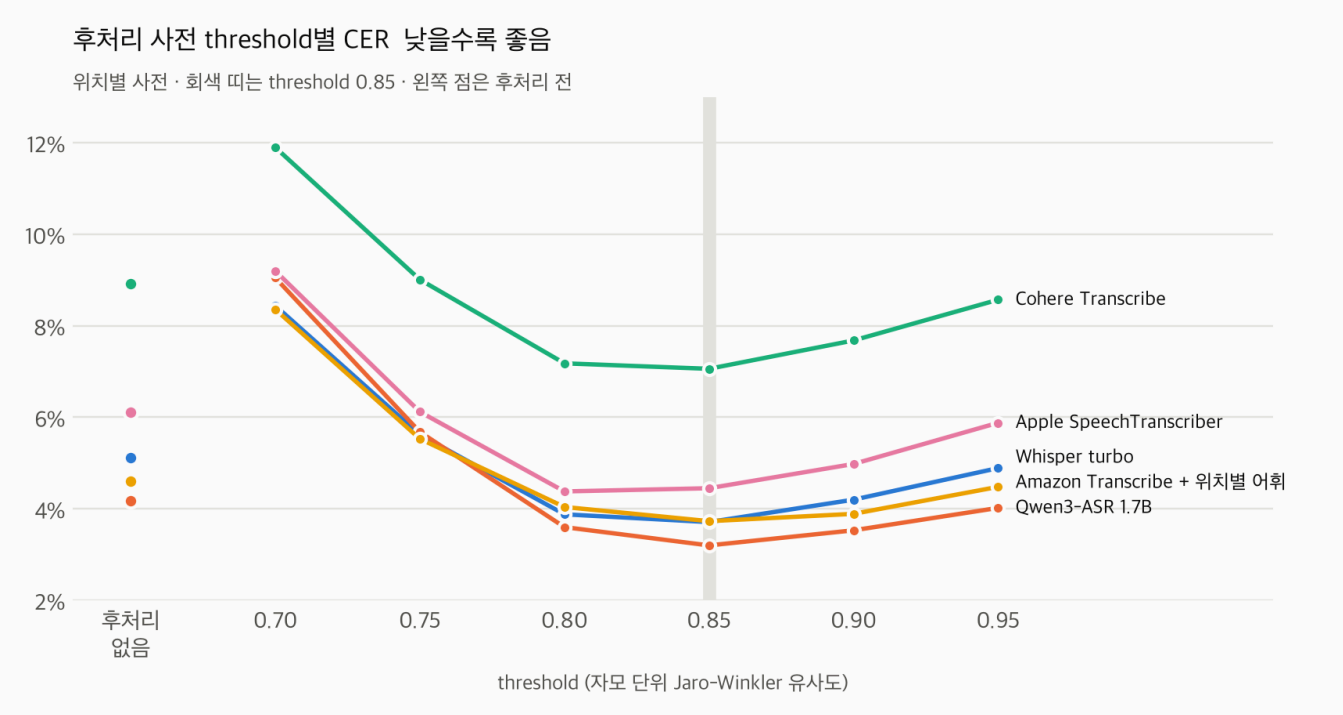
Whisper turbo가 받아쓰기 사전 없이 받아쓴 결과에 후처리 사전을 적용했습니다.

한 줄 요약: 자모 단위 · threshold 0.85가 CER이 가장 낮고, 음절 단위는 0.85에서 거의 고치지 못합니다.

방식	0.70	0.75	0.80	0.85	0.90	0.95
음절 단위 · 위치별 사전	5.02% / 88.0%	4.45% / 88.0%	4.91% / 69.9%	4.99% / 66.2%	5.07% / 66.2%	5.12% / 66.2%
자모 단위 · 위치별 사전	8.44% / 98.5%	5.62% / 97.0%	3.88% / 97.0%	**3.71% / 96.2%**	4.20% / 88.0%	4.89% / 69.2%
자모 단위 · 그 문장을 뺀 사전	10.00% / 87.2%	6.80% / 87.2%	4.93% / 88.0%	**4.42% / 87.2%**	4.63% / 80.5%	4.98% / 68.4%
자모 단위 · 전체 사전 (336개)	28.98% / 92.5%	20.23% / 92.5%	10.23% / 92.5%	6.12% / 91.7%	4.98% / 85.0%	5.12% / 69.2%

* 칸 안은 CER / 전각명 인식률입니다. 후처리 전은 5.12% / 66.2%입니다.
* CER은 낮을수록, 전각명 인식률은 높을수록 좋음.

- **음절 단위로 비교하면 threshold 0.85에서 거의 바뀌지 않습니다.**
  - 3음절 단어에서 한 음절만 틀려도 음절 단위 유사도는 0.78~0.80입니다(흑례문 ↔ 흥례문 0.78, 건축문 ↔ 건춘문 0.80).
  - 같은 쌍을 자모 단위로 비교하면 0.92~0.93이 됩니다.
- **자모 단위는 threshold 0.80~0.85에서 CER이 가장 낮습니다.** 0.70~0.75로 낮추면 일반 단어까지 바꿔서(과감 → 관아 등) 오히려 나빠집니다.
- 0.85는 이 180개 발화로 고른 값입니다. 그 문장을 뺀 사전으로 바꿔도 0.85에서 CER이 가장 낮았고, 위치별 사전에서 Qwen3-ASR 1.7B·Cohere Transcribe·Amazon Transcribe + 위치별 어휘·CLOVA Speech도 0.85가 가장 낮았습니다(받아쓰기 사전 없이 받아쓴 결과 기준, Amazon Transcribe만 어휘 포함). 어휘 없는 Amazon Transcribe와 Apple SpeechTranscriber는 0.80이 0.85보다 0.03~0.07%p 낮았습니다.
- **사전은 위치별이어야 합니다.** 전체 사전은 후보가 많아 잘못 바꾸는 경우가 크게 늘었습니다. 자모 0.85 기준으로 CER이 나빠진 발화가 위치별 사전은 14개, 전체 사전은 77개였습니다.



후처리 사전: 모델별 효과 (자모 단위 · threshold 0.85)

받아쓰기 사전 없이 받아쓴 결과에 후처리 사전을 더했을 때

한 줄 요약: 모든 모델에서 CER이 낮아지고 인식률이 오릅니다. 사전에 없는 용어가 섞이면 효과가 줄지만 그래도 좋아집니다.

모델	CER (전 → 후)	전각명 (전 → 후)	용어 (전 → 후)	좋아진 / 나빠진 발화	그 문장을 뺀 사전으로 후처리 (CER / 전각명)
Whisper large-v3	5.67% → 4.30%	62.4% → 94.0%	72.7% → 92.0%	71 / 14	4.94% / 83.5%
Whisper large-v3-turbo	5.12% → 3.71%	66.2% → 96.2%	73.2% → 92.4%	69 / 14	4.42% / 87.2%
Qwen3-ASR 1.7B	4.17% → 3.20%	72.2% → 94.7%	79.4% → 94.4%	57 / 14	3.56% / 90.2%
Qwen3-ASR 0.6B	6.49% → 4.99%	57.1% → 91.7%	70.0% → 90.4%	72 / 15	5.70% / 83.5%
Cohere Transcribe	8.92% → 7.06%	48.1% → 84.2%	55.3% → 81.2%	91 / 15	7.98% / 74.4%
Amazon Transcribe	5.78% → 4.55%	56.4% → 88.7%	68.5% → 87.0%	66 / 14	5.24% / 79.0%
CLOVA Speech	3.20% → 2.78%	87.2% → 98.5%	86.6% → 95.1%	38 / 16	3.05% / 94.7%
Apple 받아쓰기	9.98% → 9.18%	48.1% → 56.4%	55.0% → 67.6%	50 / 12	9.69% / 54.9%
Apple SpeechTranscriber	6.11% → 4.45%	58.6% → 94.0%	66.0% → 88.8%	82 / 12	5.25% / 83.5%

* CER, 나빠진 발화는 낮을수록 좋음.
* 전각명·용어 인식률, 좋아진 발화는 높을수록 좋음.
* "전 → 후"는 위치별 사전으로 후처리한 값입니다.

받아쓰기 사전을 넣고 받아쓴 결과에 후처리 사전을 더했을 때

한 줄 요약: Whisper·Qwen3-ASR 1.7B·CLOVA Speech는 CER이 조금 나빠지고 용어 인식률만 오릅니다. Qwen3-ASR 0.6B는 조금 좋아지고, Amazon Transcribe는 둘 다 크게 좋아집니다.

받아쓰기 조건	CER (전 → 후)	전각명 (전 → 후)	용어 (전 → 후)	좋아진 / 나빠진 발화	그 문장을 뺀 사전 (CER 전 → 후 / 전각명 전 → 후)
Whisper large-v3 + 받아쓰기 사전	2.43% → 2.73%	99.2% → 99.2%	98.7% → 99.5%	4 / 19	3.38% → 3.71% / 90.2% → 88.7%
Whisper turbo + 받아쓰기 사전	2.76% → 2.84%	99.2% → 99.2%	96.2% → 99.1%	15 / 19	3.73% → 3.97% / 92.5% → 91.0%
Qwen3-ASR 1.7B + 받아쓰기 사전 + 붕괴 방지	2.55% → 2.61%	94.0% → 98.5%	95.3% → 98.4%	15 / 18	2.86% → 3.10% / 91.7% → 93.2%
Qwen3-ASR 0.6B + 받아쓰기 사전 + 붕괴 방지	3.94% → 3.84%	92.5% → 97.0%	89.7% → 94.8%	21 / 17	4.99% → 5.09% / 85.7% → 86.5%
CLOVA Speech + 위치별 키워드 부스팅 (가중치 1)	2.22% → 2.36%	96.2% → 98.5%	96.9% → 98.9%	9 / 16	2.69% → 2.89% / 94.0% → 94.7%
Amazon Transcribe + 위치별 어휘	4.60% → **3.73%**	69.2% → **96.2%**	79.6% → 94.2%	56 / 15	—
Apple 받아쓰기 + 위치별 문맥 문자열	8.87% → 8.13%	65.4% → 71.4%	66.4% → 77.6%	42 / 11	—

* CER, 나빠진 발화는 낮을수록 좋음.
* 전각명·용어 인식률, 좋아진 발화는 높을수록 좋음.
* Amazon Transcribe와 Apple의 그 문장을 뺀 사전 조건은 어휘·문맥 문자열을 발화마다 따로 만들어야 해서 측정하지 않았습니다.

- **Whisper·Qwen3-ASR 1.7B·CLOVA Speech에 받아쓰기 사전을 넣었으면 후처리를 더하지 않습니다.** 잘못 바꾼 발화(16~19개)가 바로잡은 발화보다 많아 CER이 조금 나빠집니다. 용어 인식률은 오르지만(Whisper turbo 96.2% → 99.1%), 사전에 없는 용어가 섞이면 Whisper는 전각명이 오히려 내려갑니다(92.5% → 91.0%).
- Qwen3-ASR 0.6B는 사전 완비 때 CER이 3.94% → 3.84%로 조금 좋아지지만, 사전에 없는 용어가 섞이면 4.99% → 5.09%로 나빠집니다. 그래서 권장 조합은 받아쓰기 사전만으로 두었습니다.
- threshold를 0.95로 올리면 받아쓰기 사전을 넣은 모델도 CER이 조금 좋아집니다(CLOVA Speech 2.22% → 2.18%, Whisper turbo 2.76% → 2.74%, Qwen3-ASR 1.7B 2.55% → 2.51%). 차이가 0.02~0.04%p로 작아서, 권장 조합에서는 후처리를 더하지 않았습니다.
- **Amazon Transcribe는 어휘에 후처리를 더하면 전각명이 69.2%에서 96.2%가 됩니다.** 어휘만으로는 반영이 약하기 때문입니다.
- 바로잡은 예(Amazon Transcribe + 위치별 어휘): 흑례문 → 흥례문 7회, 신문문 → 신무문 4회, 경회로 → 경회루 4회, 건축문 → 건춘문 3회.
- 잘못 바꾼 예(같은 조건): 생각 → 행각, 소식 → 소실, 피하 → 피휘처럼 일반 단어를 비슷한 용어로 바꾼 경우와, 향원지 → 향원정(3회)처럼 실제로 있는 다른 이름을 바꾼 경우입니다(향원지는 향원정이 있는 연못).
- 후처리에 걸리는 시간은 발화당 약 0.5ms라 대기 시간에 영향이 없습니다.

실시간 재측정 (녹음 → STT → 후처리)

주요 구성 9개를 녹음부터 처음부터 다시 돌렸습니다(MacBook Pro). 받아쓰기 직후 후처리 사전(위치별·자모 단위·threshold 0.85)을 바로 적용했고, 대기 시간에는 후처리 시간이 포함됩니다.

구성	저장된 전사로 계산 (CER / 전각명)	실시간 재측정 (CER / 전각명)	실시간 대기 (평균 / p90)	받아쓰기 결과가 같은 발화
Whisper turbo + 후처리 사전	3.71% / 96.2%	3.71% / 96.2%	0.41 / 0.43초	180 / 180
Whisper turbo + 받아쓰기 사전 + 후처리 사전	2.84% / 99.2%	2.84% / 99.2%	0.43 / 0.44초	180 / 180
Qwen3-ASR 1.7B + 후처리 사전	3.20% / 94.7%	3.20% / 94.7%	0.68 / 0.89초	180 / 180
Qwen3-ASR 0.6B + 받아쓰기 사전 + 후처리 사전	3.84% / 97.0%	3.84% / 97.0%	0.45 / 0.58초	180 / 180
Cohere Transcribe + 후처리 사전	7.06% / 84.2%	7.06% / 84.2%	0.40 / 0.49초	180 / 180
Apple SpeechTranscriber + 후처리 사전	4.45% / 94.0%	4.45% / 94.0%	0.14 / 0.17초	180 / 180
Apple 받아쓰기 + 후처리 사전	9.18% / 56.4%	9.18% / 56.4%	0.92 / 1.31초	180 / 180
Amazon Transcribe + 후처리 사전	4.55% / 88.7%	4.56% / 88.7%	1.10 / 1.50초	179 / 180
Amazon Transcribe + 위치별 어휘 + 후처리 사전	3.73% / 96.2%	3.73% / 96.2%	1.21 / 1.59초	180 / 180

* CER, 대기 시간은 낮을수록 좋음.
* 전각명 인식률, 받아쓰기 결과가 같은 발화 수는 높을수록 좋음.

- 저장된 전사에 후처리를 적용한 값이 실제로 이어서 돌린 값과 같은지 확인한 표입니다.
- **로컬 모델과 Apple 엔진은 다시 받아쓴 결과가 180개 모두 이전과 같았고**, 후처리 뒤 수치도 같았습니다.
- Amazon Transcribe는 클라우드 서비스라 어휘 없는 구성에서 1개 발화가 다르게 받아써졌고, CER 차이는 0.01%p였습니다.
- 받아쓰기와 후처리를 이어서 돌려도 대기 시간은 받아쓰기만 할 때와 거의 같았습니다. 처음 측정(1장·3.3)과의 차이는 0.03초 이내입니다.

4. 판단

4.1 사전 등록: 합니다

- **앱에 위치별 사전을 넣고, 받아쓰기 사전을 기본으로 씁니다.** 사전이 없으면 전각명 인식률이 48~72%이고(CLOVA Speech만 87.2%), 위치별 받아쓰기 사전을 넣으면 Whisper가 99.2%로 오릅니다.
- **위치별 사전은 그 구역 해설에 나오는 전각명·용어를 빠짐없이 담습니다.** 사전에 없는 용어가 섞이면 Whisper turbo의 전각명은 92.5%로 내려가고, 놓친 용어의 대부분(61건 중 53건)이 사전에 없던 용어였습니다.
- **받아쓰기 사전이 없거나 약한 모델에는 후처리 사전(위치별·자모 단위·threshold 0.85)을 더합니다.** Amazon Transcribe는 전각명이 69.2%에서 96.2%로, Cohere는 48.1%에서 84.2%로 오릅니다.
- **받아쓰기 사전을 넣은 Whisper·Qwen3-ASR·CLOVA Speech에는 후처리를 더하지 않습니다.** Whisper·Qwen3-ASR 1.7B·CLOVA Speech는 CER이 조금 나빠지고, Qwen3-ASR 0.6B는 사전에 없는 용어가 섞이면 나빠집니다. 오르는 용어 인식률도 사전 완비일 때만 확실합니다.
- **Qwen3-ASR을 쓰면 붕괴 방지를 반드시 넣습니다.** 사전 목록 출력 1건이 CER을 0.8%p 올렸습니다.
- **사전은 위치별로 나눕니다.** 전체 사전(336개)은 받아쓰기 사전에서 위치별보다 효과가 작거나 오히려 나빴고(Amazon Transcribe 전각명 63.9% 대 위치별 69.2%, Qwen3-ASR 1.7B는 CER 8.56%에 붕괴 2건), 후처리 사전에서는 잘못 바꾸는 발화가 크게 늘었습니다(나빠진 발화 77개 대 14개).

4.2 파인튜닝: 모델별 판단

모델	파인튜닝 가능 여부	권장 사전 조합	놓친 용어 (447건 중, 완비 / 누락)	파인튜닝 필요성
Whisper large-v3	가능 (가중치 공개)	받아쓰기 사전	6 / 52	**필요 없음**. 놓친 용어 대부분이 사전에 없던 용어라 사전을 채우는 것으로 해결
Whisper large-v3-turbo	가능 (가중치 공개)	받아쓰기 사전	17 / 61	**필요 없음**. 이유는 위와 같음
Qwen3-ASR 1.7B	가능 (가중치 공개)	받아쓰기 사전 + 붕괴 방지	21 / 38	**필요 없음**
Qwen3-ASR 0.6B	가능 (가중치 공개)	받아쓰기 사전 + 붕괴 방지	46 / 82	사전으로 대부분 해결
CLOVA Speech	**불가** (빌더에 학습 기능 없음. 키워드 부스팅·인식 결과 보정만 제공)	키워드 부스팅 (가중치 1)	14 / 34	파인튜닝은 불가하지만, 키워드 부스팅만으로 CER이 가장 낮음
Cohere Transcribe	가능 (가중치 공개)	후처리 사전 (받아쓰기 사전 기능 없음)	84 / 139	이 모델을 쓰면 필요. 사전 완비에서도 전각명을 6건 중 1건꼴로 놓침
Amazon Transcribe	**한국어 불가** (사용자 지정 언어 모델 미지원)	어휘 + 후처리 사전	26 / 98	파인튜닝은 불가하지만, 사전 완비 때는 후처리로 대부분 해결
Apple 받아쓰기	불가	후처리 사전 (PWA에서는 받아쓰는 도중 사전을 넣을 수 없음)	145 / 179	파인튜닝 불가, 후처리로도 부족
Apple SpeechTranscriber	불가	후처리 사전	50 / 97	파인튜닝 불가 (PWA에서는 쓸 수 없음)

* 놓친 용어는 낮을수록 좋음.
* CER·인식률은 3.5의 "모델별 권장 사전 조합" 표에 있습니다.

- "가능 (가중치 공개)"는 모델 가중치가 공개되어 있어, 우리 음성과 정답 데이터로 직접 추가 학습시킬 수 있다는 뜻입니다. 학습에는 데이터와 GPU가 필요하고, 이번에 녹음한 데이터는 180개(약 23분)입니다.

결론

- **권장 구성(Whisper turbo, Qwen3-ASR 1.7B)은 파인튜닝하지 않습니다.**
  - 사전 완비 때 남는 용어 오류는 turbo 17건, Qwen3-ASR 1.7B 21건입니다. 그 밖의 오류는 숫자 표기(서른 단 ↔ 30단), 어미(돼 ↔ 되어) 차이와 일반 단어 오인식(즉위식 → 직위식, 지반 → 집안 등)입니다.
  - 사전에 없는 용어가 섞일 때 늘어나는 오류는 대부분 사전에 없던 용어라서, 위치별 사전을 채우면 줄어듭니다.
- **다른 모델을 고르면 판단이 달라집니다.**
  - CLOVA Speech는 파인튜닝이 불가능하지만, 키워드 부스팅만으로 CER 2.22%로 가장 낮습니다.
  - Cohere Transcribe는 후처리로 전각명 84.2%까지 오르고, 그 이상은 파인튜닝이 필요합니다.
  - Amazon Transcribe는 파인튜닝이 불가능하지만, 어휘와 후처리 사전으로 전각명 96.2%까지 오릅니다.
  - Apple 받아쓰기는 파인튜닝도 불가능하고, 후처리를 해도 전각명 56.4%입니다.

4.3 권장 구성

순위는 집 서버(1안)를 먼저, 클라우드(2안)를 다음에 두었습니다. 정확도(CER)만 보면 CLOVA Speech가 가장 좋습니다.

순위	구성	CER / 전각명 (완비)	CER / 전각명 (누락)	발화당 대기	조건
1	**Z6 G4 + Whisper large-v3-turbo(faster-whisper fp16) + 위치별 받아쓰기 사전**	2.78% / 99.2%	3.73% / 92.5%	0.28초 + 업로드	폰에서 집 장비로 들어오는 접속 경로 필요
1 대안	Z6 G4 + Qwen3-ASR 1.7B(PyTorch fp16) + 위치별 받아쓰기 사전 + 붕괴 방지	2.55% / 94.0%	2.86% / 91.7%	0.93초 + 업로드	1안과 같은 서버. CER이 turbo보다 낮고, 사전에 없는 용어가 섞여도 CER이 크게 오르지 않음
2	CLOVA Speech + 위치별 키워드 부스팅(가중치 1)	**2.22% / 96.2%**	**2.69% / 94.0%**	2.04초 (파일 업로드·네트워크 포함)	집 장비 없이 구성. CER이 가장 낮음. 요청 1건 5원(15초 단위). 대기가 2초 기준을 조금 넘음
2 대안	Amazon Transcribe + 위치별 사용자 지정 어휘 + 후처리 사전(자모 0.85)	3.73% / 96.2%	5.24% / 79.0% (어휘 없이)	1.19초 (네트워크 포함)	집 장비 없이 구성. 2초 기준 안에 듦. 10초 질문 약 $0.0017. 후처리는 앱 서버에서 발화당 약 0.5ms
3	Mac mini + Whisper large-v3-turbo(mlx-whisper fp16) + 위치별 받아쓰기 사전	2.76% / 99.2%	3.73% / 92.5%	1.61초 + 업로드	1안 장비가 멈췄을 때의 대체용
쓰지 않음	폰 브라우저 안 실행(WebGPU), 키보드 받아쓰기	— / 56.4% 이하	—	—	iPhone 탭 강제 종료(Android 미측정), 또는 후처리 사전을 써도 전각명 56.4%

* CER, 발화당 대기는 낮을수록 좋음.
* 전각명 인식률은 높을수록 좋음.
* 완비·누락의 뜻은 3.5와 같습니다. 1안·3안의 완비 값은 각 장비, 누락 값과 1 대안의 정확도는 MacBook Pro에서 잰 값입니다. 1 대안의 대기 시간은 Z6 G4에서 붕괴 방지 없이 잰 값입니다.

- **1안을 Whisper turbo로 두는 이유**
  - 사전에 용어가 들어 있으면 전각명 인식률이 99.2%로 가장 높습니다(large-v3와 같음).
  - 전각명 99.2%인 구성 중 가장 빠르고(0.28초), 같은 모델을 Mac mini 대체용(1.61초)으로도 쓸 수 있습니다.
  - CLOVA Speech보다 CER은 조금 높지만(2.78% 대 2.22%), 요청마다 내는 요금이 없습니다. 대기는 서버 처리 시간 0.28초에 폰 → 서버 업로드(압축하면 약 23KB)가 더해지는 정도라, CLOVA Speech(업로드 포함 2.04초)보다 2초 기준에 여유가

큽니다. Qwen3-ASR 1.7B는 Mac mini(부하 상태)에서 3.00초로 2초 기준을 넘었습니다.

- **Whisper large-v3를 1안으로 두지 않는 이유**
  - 정확도는 turbo보다 조금 좋습니다(Z6 G4 CER 2.45% 대 2.78%, 놓친 용어 6건 대 17건).
  - 하지만 Z6 G4에서 약 2배 느리고(0.55초), Mac mini(부하 상태)에서는 2.95초로 2초 기준을 넘어 대체용으로 쓸 수 없습니다.
- **1 대안(Qwen3-ASR 1.7B)으로 바꾸는 경우**
  - 사용자가 위치별 사전에 없는 말을 많이 할 것 같을 때입니다. 사전에 없는 용어가 섞이면 CER 2.86%로 Whisper turbo(3.73%)보다 낮고, 용어 인식률도 91.5%로 더 높습니다(Whisper turbo 86.4%).
  - 같은 서버에서 모델만 바꾸면 되고, Z6 G4에서 0.93초로 2초 기준 안에 듭니다.
- **집 장비 없이 클라우드로 간다면 2안 CLOVA Speech**
  - CER이 두 조건 모두 가장 낮고(2.22%, 2.69%), 사전에 없는 용어가 섞여도 전각명 94.0%입니다.
  - 대신 대기가 평균 2.04초(파일 업로드 방식)로 2초 기준을 조금 넘고, 요청 1건에 5원입니다. 2초 기준을 꼭 지켜야 하면 2 대안 Amazon Transcribe(1.19초)입니다.

부록

A. 산출물 (`STT학습데이터/Benchmark/`)

경로	내용
`results/`	MacBook Pro 결과 (Amazon Transcribe·Apple 포함, 그 문장을 뺀 사전 `+loo`·붕괴 방지 `-guard` 조건 포함)
`data/hints_by_location.json`, `data/hints_loo.json`	위치별 사전, 그 문장을 뺀 위치별 사전(녹음 ID별) — `prepare.py`가 만듦
`results_z6g4/`, `results_macmini/`	집 서버 결과 (`summary.csv`, `per_utterance.csv`, `term_misses.csv`, 원본 jsonl)
`results_webgpu/`	맥 브라우저 WebGPU 결과와 실행 로그
`results_iphone/`	iPhone 시도 로그(탭 종료 지점)와 base 1건 결과
`run_device.sh`	집 장비용 실행 스크립트 (Linux CUDA·macOS 공용)
`webgpu/index.html`, `webgpu/serve.py`	브라우저 측정 페이지와 로컬 서버 (받아쓰기 사전 입력·반복 방지·원격 로그 포함)
`devices_table.py`	장비별 결과를 한 표로 합치는 스크립트 (`results_devices.csv`)
`postcorrect.py`, `results_postcorrect/`	후처리 사전 (유사도 threshold 방식) 코드와 결과 (`summary.csv`, `changes.csv` : 조건별 교정 횟수·좋아진/나빠진 발화)
`run_live.sh`, `results_live/`, `compare_live.py`	녹음 → STT → 후처리를 처음부터 다시 돌린 실시간 측정 (`hyp_raw` : 후처리 전 전사, `compare.csv` : 저장된 전사와 비교)
`run_loo.sh`	그 문장을 뺀 사전·Qwen3-ASR 붕괴 방지 조건 측정 스크립트
`run_clova.py`	CLOVA Speech 장문 인식(sync) 측정 스크립트 (`--hint none|location|loo|global`, `--weight` 부스팅 가중치)
`charts.py`, `report_assets/`	보고서 그래프

B. 출처

- WebKit, Safari 26 WebGPU: https://webkit.org/blog/17333/webkit-features-in-safari-26-0/
- WebKit 버그 268816 (iPhone 메모리 한도 1.5GB 언급): https://bugs.webkit.org/show_bug.cgi?id=268816
- WebKit 버그 324370 (웹사이트당 1.88GB): https://bugs.webkit.org/show_bug.cgi?id=324370
- Chrome WebGPU (Android): https://developer.chrome.com/blog/new-in-webgpu-121
- transformers.js 4.3.0 (Safari WebGPU 지원): https://github.com/huggingface/transformers.js/releases/tag/4.3.0
- transformers.js Whisper `prompt_ids` 미지원 이슈: https://github.com/huggingface/transformers.js/issues/923
- Cohere Transcribe 브라우저 지원: https://github.com/huggingface/transformers.js/pull/1610
- Apple SpeechAnalyzer 브라우저 노출 없음: https://blog.addpipe.com/apple-speechanalyzer-api/
- Amazon Transcribe 언어별 지원 기능: https://docs.aws.amazon.com/transcribe/latest/dg/supported-languages.html
- Amazon Transcribe 요금(1초 단위 청구, 최소 요금 없음, 사용자 지정 어휘 포함): https://aws.amazon.com/transcribe/pricing/
- Amazon Transcribe 서울 리전 스트리밍 단가(초당 $0.0001667, AWS Price List): https://pricing.us-east-1.amazonaws.com/offers/v1.0/aws/transcribe/current/ap-northeast-2/index.json
- CLOVA Speech 요금(장문 인식 Basic 15초당 5원, Free 플랜 월 20분): https://www.ncloud.com/product/aiService/clovaSpeech

- CLOVA Speech 장문 인식 로컬 파일 API(키워드 부스팅 `boostings`): https://api.ncloud-docs.com/docs/ai-application-service-clovaspeech-longsentence-local
- CLOVA Speech 단문 인식 API(부스팅 단어 3글자 이상): https://api.ncloud-docs.com/docs/ai-application-service-clovaspeech-shortsentence
- 모델: `onnx-community/whisper-large-v3-turbo`, `onnx-community/whisper-small`, `onnx-community/whisper-base`, `mobiuslabsgmbh/faster-whisper-large-v3-turbo`, `Systran/faster-whisper-large-v3`, `mlx-community/whisper-large-v3-*`, `Qwen/Qwen3-ASR-*-hf`, `CohereLabs/cohere-transcribe-03-2026`