궁금(宮今) STT 소음·동시 발화·VAD 측정 보고서

작성 안기겸 · 2026-11-02 · 경복궁 해설 발화 녹음 180개에 배경 소리를 합성해 측정 · Amazon Transcribe(위치별 어휘 + 후처리 사전) 기준

목차

용어 풀이
1. 요약
2. 왜 쟀나
3. 어떻게 쟀나
    3.1 배경 소리 합성
    3.2 측정 구성
4. 결과
    4.1 인식 정확도
    4.2 VAD
    4.3 전사 예시 (옆 사람 1명, 10 dB)
5. 설계에 반영할 것
6. 한계와 다음 측정
부록. 파일과 재현 방법

용어 풀이

용어	뜻
CER	글자 오류율. 정답 문장과 비교해 틀린 글자 비율. 낮을수록 좋음
전각명 인식률	광화문·근정전 같은 건물 이름을 맞게 받아쓴 비율
붕괴 발화	글자 절반 이상이 틀린(CER 50% 이상) 발화. 자막으로 쓸 수 없는 수준
배경 세기 차이(dB)	해설사 목소리가 배경 소리보다 얼마나 큰지. 20 dB = 목소리가 10배 큼(조용한 편), 0 dB = 같은 크기(매우 시끄러움)
웅성거림	여러 사람 말소리가 겹친 군중 소음. 다른 낭독자 6명의 녹음을 겹쳐 만듦
옆 사람 1명	해설사 바로 옆에서 다른 사람 1명이 계속 말하는 상황. 다른 낭독자 1명의 녹음을 같은 구간에 겹쳐 만듦
VAD	음성 구간 검출. 마이크 소리에서 "지금 말하는 중인가"를 판단해 STT로 보낼 구간을 자르는 장치
무음 구간 오작동	해설사가 말을 쉬는 동안 VAD가 배경 소리를 말로 착각해 켜진 경우

1. 요약

- **웅성거림은 해설사 목소리보다 10 dB 이상 작으면 문제가 없습니다.** CER 3.73%(깨끗) → 3.89%(20 dB) → 4.45%(10 dB)로 거의 그대로이고 전각명 인식률도 95% 수준을 지킵니다. 5 dB부터 전각명 84%로 떨어지고, 0 dB에서는 발화 3분의 1이 붕괴합니다.
- **옆에서 다른 사람이 말하는 것이 군중 소음보다 훨씬 해롭습니다.** 10 dB 차이에서 이미 CER이 2배(8.26%)가 되고, 5 dB면 붕괴 29건, 0 dB면 거의 전부 못 씁니다.
- **VAD는 "말소리인지"만 가리고 "해설사 목소리인지"는 가리지 못합니다.** Silero·WebRTC 모두 배경 말소리에 켜져서, 20 dB 웅성거림에서도 해설사가 쉬는 동안 파일의 45~69%가 오작동했습니다. 음량 문턱(−10 dB)과 시작 0.1초·유지 0.3초 조건을 붙이면 20 dB 환경에서는 오작동 0.6%·검출률 96.7%로 막을 수 있으나, 10 dB 이하에서는 어떤 방법도 막지 못합니다.
- **설계 반영**: ① 해설사 입 가까이의 마이크(헤드셋·핀마이크)로 배경 대비 10 dB 이상을 확보하는 것이 가장 효과가 큽니다. ② VAD는 Silero + 음량 문턱 + 시작/유지 조건으로 "조용할 때 전송 차단" 용도로만 쓰고, ③ 시끄러운 곳에서는 VAD 자동 판단 대신 해설사가 말하기 버튼으로 켜고 끄는 방식을 기본으로 둡니다. ④ 11월 8일 현장 테스트에서 실제 배경 세기 차이를 재어 어느 조건에 해당하는지 확인합니다.

2. 왜 쟀나

앞선 STT 엔진 비교(10월 25일)는 전부 조용한 실내에서 낭독한 녹음이었습니다. 실제 해설은 관광객이 많은 야외에서 이루어지고, 옆 팀 해설사나 관람객 말소리가 섞입니다. 상세개발계획서의 "STT→번역 스트리밍 파이프라인(VAD 포함)" 항목을 만들기 전에 다음 두 가지를 알아야 했습니다.

1. 배경 소리가 커질수록 Transcribe의 인식률이 얼마나 떨어지는가.
2. 해설사가 말을 쉬는 동안 VAD가 배경 소리를 말로 착각하는가(착각하면 엉뚱한 자막이 나가고 비용이 듭니다).

3. 어떻게 쟀나

3.1 배경 소리 합성

현장 녹음 대신 기존 180개 녹음에 배경을 섞었습니다. 단계별 비교가 되고, 정답 문장이 그대로 있어 기존 지표와 바로 비교할 수 있기 때문입니다.

항목	방법
원 녹음	10월 벤치마크와 같은 180개(16 kHz 모노)
웅성거림	같은 낭독자·같은 해설 위치를 뺀 다른 녹음 6개를 겹쳐 만든 군중 소음
옆 사람 1명	다른 낭독자 1명의 녹음을 이어 붙여 해설사 발화 구간 전체에 겹침
세기 맞추기	해설사 발화 구간(Silero VAD로 찾음)의 음량을 재고, 배경을 그보다 20·10·5·0 dB(웅성거림) / 10·5·0 dB(옆 사람) 작게 맞춤
인식 정확도용	원 녹음과 같은 구간만 (180개 × 7조건)
VAD용	앞 1.5초·뒤 2.5초 무음을 붙이고 배경은 그 구간에도 깔아, "해설사가 쉬는 동안" 배경에 켜지는지 봄

3.2 측정 구성

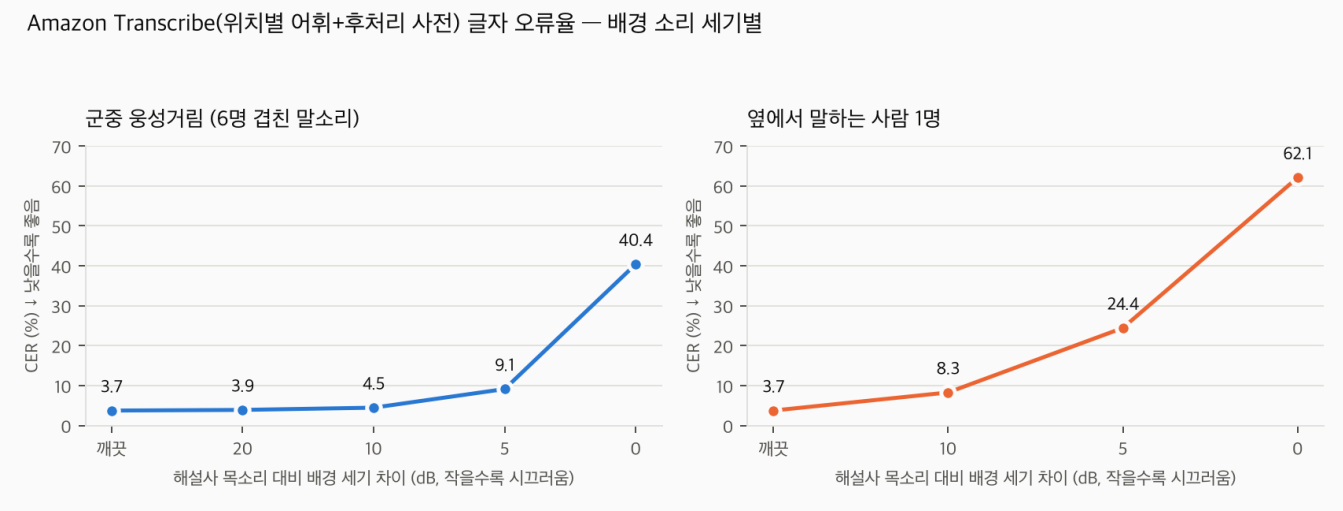
항목	내용
STT	Amazon Transcribe 스트리밍(서울, ko-KR) + 위치별 사용자 지정 어휘 + 후처리 사전(자모·0.85). 팀이 결정한 구성 그대로
VAD 후보	Silero VAD(문턱 0.5·0.7), WebRTC VAD(가장 엄격한 모드 3), Silero + 음량 문턱(–10·–15 dB), Silero + 음량 문턱(–15·–10 dB) + 시작 0.1초/유지 0.3초
VAD 정답	깨끗한 녹음에서 Silero VAD가 찾은 발화 구간
지표	인식: CER·완전 일치·붕괴 발화·용어/전각명 인식률. VAD: 발화 검출률, 비발화 오검출률, 무음 구간 오작동 파일 비율(0.3초 이상 연속으로 켜짐), 시작 지연
비용	Transcribe 7조건 약 1.6달러. VAD는 맥북에서 처리

"음량 문턱"은 해설사 발화 세기(깨끗한 녹음에서 잰 값)보다 10 또는 15 dB 이상 작은 프레임은 말로 치지 않는 것입니다. 앱에서는 해설사가 처음 몇 초 말할 때 세기를 재 두는 방식으로 구현할 수 있습니다.

4. 결과

4.1 인식 정확도

배경	해설사 대비 세기 차이 (dB)	CER (%) ↓	완전 일치 (%) ↑	붕괴 발화 (개, CER≥50%) ↓	용어 인식률 (%) ↑	전각명 인식률 (%) ↑
깨끗한 녹음 (기준)	—	3.73	41.1	0	94.2	96.2
웅성거림	20	3.89	40.6	0	93.1	96.2
웅성거림	10	4.45	33.3	0	92.2	94.7
웅성거림	5	9.11	17.8	0	82.8	84.2
웅성거림	0	40.39	7.8	63	53.5	57.9
옆 사람 1명	10	8.26	27.8	4	88.6	88.7
옆 사람 1명	5	24.42	12.8	29	74.0	79.0
옆 사람 1명	0	62.07	0.6	107	43.0	47.4



- 웅성거림 20·10 dB는 깨끗한 녹음과 사실상 같습니다(CER 차이 0.2~0.7%p, 붕괴 0건).
- 웅성거림 5 dB에서 전각명이 84%로 떨어지고, 0 dB에서는 180개 중 63개가 붕괴합니다.
- 옆 사람 1명은 10 dB에서 이미 CER 8.26%(붕괴 4건), 5 dB에서 24.4%(붕괴 29건), 0 dB에서 62%(붕괴 107건)입니다. 같은 세기 차이의 웅성거림보다 2~3배 나쁩니다. 겹친 말소리가 또렷한 한국어라 Transcribe가 두 사람의 말을 섞어 받아쓰기 때문입니다(전사 길이는 정답과 같은데 내용이 섞임).
- 대기 시간은 조건과 무관하게 평균 1.25초, p90 1.7초로 깨끗한 녹음(1.19초·1.59초)과 같습니다.

4.2 VAD

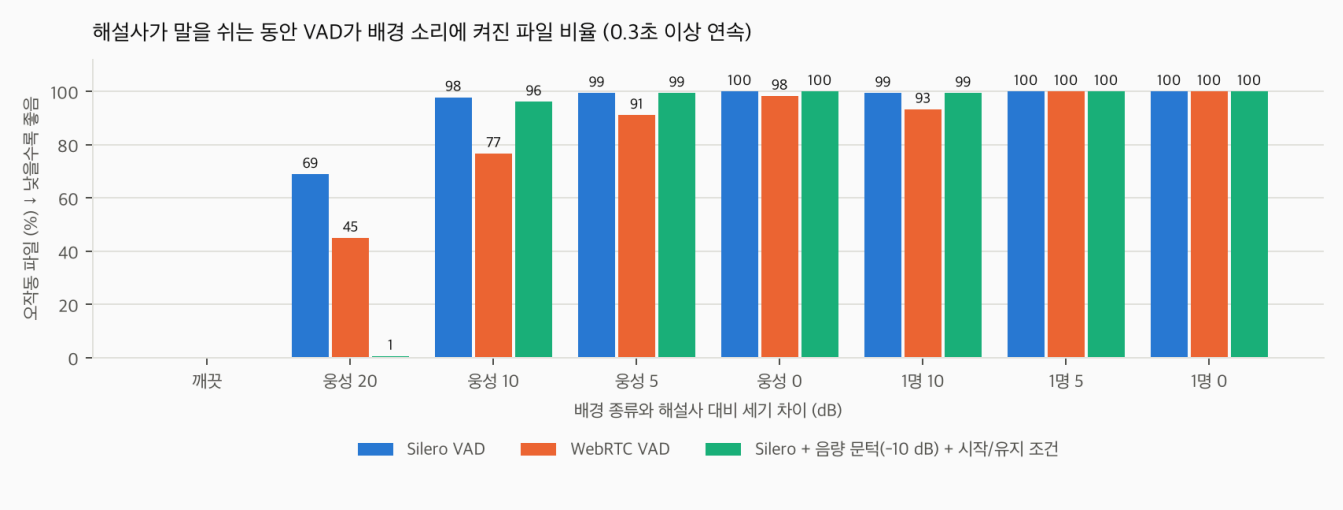
해설사가 쉬는 동안 배경에 켜진 파일 (%) ↓ | 검출기 | 깨끗 | 웅성거림 20 | 웅성거림 10 | 웅성거림 5 | 웅성거림 0 | 옆 사람 1명 10 | 옆 사람 1명 5 | 옆 사람 1명 0 | |---|---|---|---|---|---|---|---|---| | Silero VAD (문턱 0.5) | 0.0 | 68.9 | 97.8 | 99.4 | 100.0 | 99.4 | 100.0 | 100.0 | | Silero VAD (문턱 0.7) | 0.0 | 60.0 | 95.0 | 99.4 | 100.0 | 99.4 | 100.0 | 100.0 | | WebRTC VAD (모드 3) | 0.0 | 45.0 | 76.7 | 91.1 | 98.3 | 93.3 | 100.0 | 100.0 | | Silero + 음량 문턱 −10 dB | 0.0 | 0.0 | 37.2 | 97.2 | 100.0 | 28.3 | 84.4 | 95.0 | | Silero + 음량 문턱 −15 dB | 0.0 | 0.0 | 93.3 | 99.4 | 100.0 | 82.2 | 97.8 | 100.0 | | Silero + 음

량 문턱 –15 dB + 시작 0.1초/유지 0.3초 | 0.0 | 14.4 | 98.3 | 99.4 | 100.0 | 100.0 | 100.0 | 100.0 | | Silero + 음량 문턱 –10 dB + 시작 0.1초/유지 0.3초 | 0.0 | 0.6 | 96.1 | 99.4 | 100.0 | 99.4 | 100.0 | 100.0 |

해설사 발화 프레임 검출률 (%) ↑ | 검출기 | 깨끗 | 웅성거림 20 | 웅성거림 10 | 웅성거림 5 | 웅성거림 0 | 옆 사람 1명 10 | 옆 사람 1명 5 | 옆 사람 1명 0 | |---|---|---|---|---|---|---|---|---| | Silero VAD (문턱 0.5) | 96.7 | 98.6 | 99.8 | 99.9 | 100.0 | 99.5 | 99.5 | 99.2 | | Silero VAD (문턱 0.7) | 95.6 | 97.6 | 99.5 | 99.8 | 99.9 | 99.2 | 99.1 | 98.9 | | WebRTC VAD (모드 3) | 91.4 | 91.7 | 93.2 | 94.4 | 96.7 | 96.2 | 96.8 | 96.6 | | Silero + 음량 문턱 –10 dB | 70.1 | 71.1 | 85.0 | 94.0 | 97.5 | 80.9 | 85.4 | 86.4 | | Silero + 음량 문턱 –15 dB | 79.5 | 82.5 | 95.9 | 98.6 | 99.5 | 89.9 | 92.2 | 92.0 | | Silero + 음량 문턱 –15 dB + 시작 0.1초/유지 0.3초 | 98.3 | 98.5 | 99.9 | 100.0 | 100.0 | 99.5 | 99.7 | 99.6 | | Silero + 음량 문턱 –10 dB + 시작 0.1초/유지 0.3초 | 96.4 | 96.7 | 99.2 | 99.9 | 100.0 | 98.6 | 99.1 | 99.1 |

비발화 프레임 오검출률 (%) ↓ | 검출기 | 깨끗 | 웅성거림 20 | 웅성거림 10 | 웅성거림 5 | 웅성거림 0 | 옆 사람 1명 10 | 옆 사람 1명 5 | 옆 사람 1명 0 | |---|---|---|---|---|---|---|---|---| | Silero VAD (문턱 0.5) | 0.2 | 44.7 | 86.0 | 95.1 | 97.0 | 76.0 | 76.9 | 75.6 | | Silero VAD (문턱 0.7) | 0.1 | 37.5 | 80.3 | 93.1 | 95.5 | 74.0 | 75.4 | 74.2 | | WebRTC VAD (모드 3) | 0.7 | 25.3 | 56.4 | 70.4 | 84.7 | 56.7 | 66.0 | 69.0 | | Silero + 음량 문턱 –10 dB | 0.1 | 0.1 | 33.0 | 70.1 | 87.9 | 28.7 | 46.6 | 54.6 | | Silero + 음량 문턱 –15 dB | 0.1 | 2.6 | 64.6 | 86.4 | 94.5 | 46.1 | 57.5 | 62.2 | | Silero + 음량 문턱 –15 dB + 시작 0.1초/유지 0.3초 | 5.2 | 7.9 | 83.9 | 94.4 | 97.4 | 74.0 | 80.1 | 80.8 | | Silero + 음량 문턱 –10 dB + 시작 0.1초/유지 0.3초 | 3.9 | 4.1 | 56.9 | 89.3 | 96.4 | 53.4 | 74.3 | 78.0 |

처리 시간(맥북 CPU, 10초 파일 1개): Silero 계열 약 46 ms, WebRTC 1.1 ms — 둘 다 실시간보다 100배 이상 빠릅니다.



- 깨끗한 녹음에서는 세 VAD 모두 오작동 0%, 검출률 91~97%입니다.
- 배경이 말소리이면 Silero·WebRTC는 그것도 "말"로 봅니다. 20 dB 웅성거림에서 이미 Silero 69%, WebRTC 45%의 파일이 쉬는 구간에서 켜졌고, 10 dB 이하에서는 거의 전부 켜졌습니다. 문턱을 0.7로 올려도 거의 달라지지 않습니다.
- 음량 문턱은 20 dB 환경에서만 듣습니다. 문턱만 붙이면(–10 dB) 작은 음절이 잘려 검출률이 70%로 떨어지지만, 시작 0.1초/유지 0.3초 조건을 더하면 검출률 96~97%를 되찾으면서 20 dB 웅성거림의 오작동을 0.6%로 막습니다(–15 dB는 14%). 10 dB부터는 배경이 문턱을 넘어 어느 조합이든 다시 켜집니다.
- 시작 지연은 깨끗한 녹음에서 5~25 ms로 세 후보 모두 문제없습니다(배경이 있을 때 음수로 나오는 것은 배경 때문에 이미 켜져 있던 것입니다).

4.3 전사 예시 (옆 사람 1명, 10 dB)

정답	Transcribe 결과
광화문은 석축 기단에 홍예문 세 개를 내고, 그 위에 2층 문루를 올린 구조입니다.	광화문은 석축 기단에 홍예문 세 개를 내고 그 위에 이층 문루를 올린 구조입니다.
가운데 홍예는 임금이 드나드는 문이었고, 그 천장에는 남쪽을 지키는 주작이 그려져 있습니다.	가운데 홍해는 임금이 드나드는 문이었고 그 천장에는 남쪽을 지키는 주작이 그려져 있습니다.

같은 문장을 웅성거림 5 dB에서 받아쓰면 "가운데 홍해는 곰곰히 드다르는 문이 없고 … 주장이 그려져 있습니다"처럼 조사와 용어가 함께 무너집니다.

5. 설계에 반영할 것

순서	할 일	근거
1	**해설사 마이크를 입 가까이(헤드셋·핀마이크)로 두어 배경 대비 10 dB 이상 확보**	10 dB 이상이면 CER·전각명이 깨끗한 녹음과 같음. 폰을 손에 들고 말하면 배경 대비가 작아짐
2	**VAD는 Silero + 음량 문턱 −10 dB + 시작 0.1초/유지 0.3초로, "조용할 때 전송 차단" 용도로만**	20 dB 환경에서 오작동 0.6%·검출 97%. 비용 절감(쉬는 동안 Transcribe 과금 없음)과 엉뚱한 자막 방지
3	**시끄러운 곳에서는 해설사가 말하기 버튼으로 켜고 끄는 수동 방식을 기본으로**	10 dB 이하에서는 어떤 VAD도 배경 말소리와 해설사를 구분 못 함
4	**옆 팀 해설사와 거리를 두는 운영 안내**	옆 사람 1명이 웅성거림보다 2~3배 해로움
5	**11월 8일 현장 테스트에서 앱이 해설사 발화 세기와 배경 세기를 로그로 남기도록**	실제 현장이 20·10·5 dB 중 어디인지 알아야 2·3번의 기본값을 정할 수 있음

6. 한계와 다음 측정

- 배경이 같은 녹음 세트의 한국어 낭독을 합성한 것이라, 실제 현장의 외국어 관람객 말소리·바람·안내 방송·발소리와는 다릅니다. 외국어 말소리는 Transcribe(ko-KR)가 섞어 받아쓸 가능성이 한국어보다 낮을 수 있습니다.
- 옆 사람 1명 조건은 발화 구간 전체가 겹치는 최악의 경우입니다. 실제로는 부분적으로 겹칩니다.
- VAD 정답을 Silero로 만들었으므로 Silero에 약간 유리합니다. 음량 문턱의 기준 세기도 정답에서 가져왔으므로 앱에서는 해설사 목소리 보정 단계가 필요합니다.
- 다음 측정: 현장 테스트(11월 8일)에서 실제 배경 세기 차이 분포와 녹음을 얻어 이 표의 어느 열에 해당하는지 확인하고, 필요하면 그 녹음으로 재측정합니다.

부록. 파일과 재현 방법

파일	내용
`mix_noise.py`	배경 합성(7조건 × 180개, VAD용 무음 구간 포함). 결과 `.cache/noisy/`
`run_noise.sh`	7조건 Transcribe 전사(`run_transcribe.py --wav-dir … --tag …`)
`results_noise/summary.csv`	조건별 인식 지표 (`evaluate.py results_noise`)
`vad_eval.py`	VAD 측정. 결과 `results_noise/vad_summary.csv` , `vad_per_file.csv`
`noise_charts.py`	그래프 2개 (`report_assets/noise_cer.png` , `vad_false.png`)
`noise_report_tables.py`	이 보고서의 표를 CSV에서 갱신

`python mix_noise.py && ./run_noise.sh && python evaluate.py results_noise python vad_eval.py && python noise_charts.py && python noise_report_tables.py && python make_pdf.py STT_소음_VAD_측정_보고서.md`