궁금(宮今) 현장 녹음 받아쓰기·영어 번역 용어집 측정 보고서

작성 안기겸 · 2026-11-09 · 경복궁 현장 녹음 15문장(2026-11-08 녹음)과 해설 문장 300개로 측정 · Amazon Transcribe(위치별 단어집 + 교정 사전), Amazon Translate(사용자 지정 용어집) 기준

목차

용어 풀이
1. 요약
2. 한 일의 범위와 순서
3. 팀 계정 단어집·용어집 등록
    3.1 등록한 것
    3.2 단어집을 위치별로 나눈 이유
    3.3 단어의 출처
    3.4 목록 37개를 백엔드 위치 71곳으로 옮긴 규칙
    3.5 묶음 이름 3개를 단어에서 뺀 이유
    3.6 번역 용어집을 영어만 올린 이유
    3.7 등록 결과
    3.8 원본 자료에서 발견한 것
4. 현장 녹음 받아쓰기
    4.1 녹음
    4.2 측정 방법과 선택 이유
    4.3 결과
    4.4 어떤 단어가 틀렸는가
    4.5 해석
5. 영어 번역 용어집 평가
    5.1 무엇을 평가했고 왜 이 지표인가
    5.2 왜 녹음이 아니라 정답 글 300문장인가
    5.3 채점 방법
    5.4 결과
    5.5 조사가 붙으면 용어집이 적용되지 않습니다
    5.6 조사가 없어도 적용되지 않은 경우
    5.7 묶음 항목
    5.8 용어집이 적용되지 않은 문장의 오역
    5.9 번역 속도와 비용
6. 용어 표기 일치율을 높이는 방법 시험
    6.1 번역이 끝난 영어를 유사도로 한 번 더 고치기
    6.2 번역 전에 용어를 영문 이름으로 바꿔 넣기
    6.3 번역 뒤 후처리 규칙 두 가지
    6.4 넣은 이름에 번역 제외 표시 씌우기
    6.5 방식 비교
    6.6 글자 수와 비용
    6.7 이 방법으로 잡히지 않는 것
7. 결론과 다음 단계
부록. 파일 위치

용어 풀이

용어	뜻
CER	글자 오류율. 정답 문장과 비교해 틀린 글자 비율. 낮을수록 좋음
단어집	Amazon Transcribe의 사용자 지정 어휘. "이 단어들이 나올 수 있다"고 미리 알려 주는 목록. 받아쓸 때 이름으로 지정하면 그 단어를 우선해서 알아들음
용어집	Amazon Translate의 사용자 지정 용어. "이 한국어 단어는 반드시 이 영어 표기로 옮긴다"는 대응표
교정 사전	받아쓴 글에서 단어집의 단어와 소리가 비슷한 단어를 찾아 그 단어로 고치는 후처리 단계
해설 위치	해설사가 서 있는 전각·구역. 백엔드는 위치 71곳을 id로 구분함
용어 표기 일치율	문장에 든 용어가 영어 결과에서 엑셀에 정한 영문 표기 그대로 나온 비율. 높을수록 좋음
묶음 항목	용어집에서 여러 용어를 한 줄로 묶어 같은 영문 표기를 준 항목. 예: 창건·중건·재건·복원·소실
조사	"은, 는, 이, 가, 을, 를, 에"처럼 단어 뒤에 붙어 쓰이는 말

1. 요약

- **팀 AWS 계정에 받아쓰기용 단어집 72개와 번역용 용어집 1개를 등록했습니다.** 단어집은 백엔드 위치 71곳마다 1개씩과 전체 1개이고, 72개 모두 정상 등록됐습니다. 용어집은 영어 표기 329행입니다.
- **경복궁 현장 소음 속 녹음에서도 Transcribe는 문장을 끊김 없이 받아썼습니다.** 15문장의 CER은 교정 전 8.9%, 교정 후 7.4%입니다. 조용한 곳에서 녹음한 180문장(3.7%)의 약 2배이고, 틀린 곳은 대부분 궁궐 용어입니다.
- **교정 사전은 현장 녹음에서도 효과가 있었습니다.** 건축문→건춘문, 흉례문→흥례문 등 8건을 바로잡았습니다. 홍예문→통회문, 품계석→통계석처럼 소리가 많이 달라진 단어는 남았습니다.
- **번역 용어집은 붙여도 18%만 정해진 영문 표기로 나왔습니다.** 용어집이 없으면 0.3%이므로 용어집 자체는 필요하지만, 지금 방식으로는 대부분의 용어에 적용되지 않습니다.
- **원인은 조사입니다.** 용어 뒤에 조사가 붙으면 용어집이 적용된 비율이 0.5%이고, 조사 없이 떨어져 있으면 63.0%입니다. 해설 문장에서 용어의 72%는 조사가 붙어 나옵니다.
- **용어집이 적용되지 않은 문장에서는 전각 이름과 궁궐 용어의 오역이 심합니다.** "사정전은 … 편전입니다"가 "The situation war is a situation …"으로 나오는 수준입니다.
- **번역하기 전에 용어를 영문 이름으로 바꿔 넣으면 일치율이 94.2%까지 오릅니다.** 전각 이름은 283개가 모두 맞았습니다. 남은 45건은 대부분 여러 용어를 한 줄로 묶은 항목입니다.
- **넣은 이름에 번역 제외 표시를 씌우면 Translate가 그 이름을 한 글자도 바꾸지 않습니다.** 아직 안 맞는 항목이 든 37문장으로 시험하니 38건 중 32건이 맞게 됐고, 300문장 전체로 환산하면 99.2%입니다.
- **번역이 끝난 영어를 유사도로 한 번 더 고치는 방법은 53.1%까지 올립니다.** 철자만 다른 전각 이름에는 잘 듣지만(80.6%), Translate가 뜻을 잘못 푼 용어는 잡지 못합니다.
- **용어 표기가 맞아도 문장의 뜻이 틀린 경우는 남습니다.** 용어집에 없는 일반 단어("임금"을 급여로 옮기는 등)의 오역입니다.

2. 한 일의 범위와 순서

순서	한 일	그렇게 한 이유
1	팀 AWS 계정에 단어집·용어집 등록	실제 서비스(백엔드)가 팀 계정의 Transcribe·Translate를 쓰므로, 측정도 같은 계정의 같은 자원으로 해야 서비스와 같은 결과가 나옴
2	현장 녹음을 Transcribe로 받아쓰고 정답과 비교	지금까지의 측정은 조용한 녹음과 합성 소음이었음. 실제 경복궁 소음에서도 받아쓰기가 되는지 먼저 확인
3	해설 문장 300개를 Translate로 번역하고 용어 표기 채점	받아쓰기 다음 단계인 영어 번역에서, 용어가 엑셀에 정한 표기대로 나오는지 확인

받아쓰기를 번역보다 먼저 확인한 이유는, 번역에 들어가는 글이 받아쓰기의 결과이기 때문입니다. 앞 단계가 현장에서 무너지면 뒤 단계를 재는 의미가 없습니다.

3. 팀 계정 단어집·용어집 등록

3.1 등록한 것

올린 것	서비스	개수	이름
받아쓰기용 단어집	Amazon Transcribe (서울 리전, 한국어)	72개	위치별 `gungeum-place-…` 71개, 전체 `gungeum-gyeongbokgung-ko` 1개
번역용 용어집	Amazon Translate (서울 리전)	1개, 329행	`gungeum-ko` (한국어 → 영어)

등록 전에 팀 계정의 기존 단어집·용어집을 조회했고, 둘 다 0개여서 덮어쓴 자원은 없습니다.

3.2 단어집을 위치별로 나눈 이유

- **벤치마크의 결론을 따랐습니다.** 조용한 녹음 180문장 측정에서, 전체 용어 336개를 한꺼번에 넣는 것보다 해설 위치에 맞는 용어만 넣는 쪽이 나았습니다.

Amazon Transcribe, 조용한 녹음 180문장	전각 이름 인식률 (↑ 높을수록 좋음)
단어집 없음	56.4%
전체 단어집 (336개)	63.9%
위치별 단어집	69.2%
위치별 단어집 + 교정 사전	96.2%

- **교정 사전도 위치별이어야 합니다.** 같은 측정에서 전체 목록으로 교정하면 후보가 많아 잘못 고치는 문장이 크게 늘었습니다(교정 뒤 CER이 나빠진 문장이 위치별 14개, 전체 77개).
- **Transcribe는 받아쓰기 연결 하나에 단어집을 하나만 지정할 수 있습니다.** 위치에 따라 단어를 바꾸려면 위치마다 단어집이 따로 있어야 합니다.
- **백엔드가 위치 id로 단어집을 찾습니다.** 백엔드 코드는 해설사의 현재 위치 id 앞에 `gungeum-`을 붙인 이름의 단어집을 엽니다. 그래서 백엔드 위치 71곳 각각에 그 이름으로 단어집이 있어야 합니다.
- **전체 단어집 1개는 위치를 모를 때 씁니다.** 엑셀 두 개의 용어·전각 이름이 모두 들어 있습니다(336개).

3.3 단어의 출처

- 원본은 `경복궁_STT_발화문_300.xlsx`의 해설 문장 300개입니다. 위치마다 "그 위치의 해설 문장에 실제로 나온 전각 이름과 용어"를 자주 나온 순서로 모았습니다.
- 이렇게 모은 위치별 목록은 37개이고, 한 목록에 5~40개가 들어 있습니다.
- `경복궁_용어.xlsx`(231행)와 `경복궁_전각.xlsx`(71행)에서 나온 이름 330개는 37개 목록 어딘가에 빠짐없이 들어 있습니다.

점검 항목	개수
엑셀 두 개에서 나온 이름(다른 표기 포함)	330
그중 위치별 목록에 들어 있는 것	330
빠진 것	0

3.4 목록 37개를 백엔드 위치 71곳으로 옮긴 규칙

해설 문장 엑셀의 "해설 위치"는 37개인데 백엔드의 위치는 71곳이어서, 아래 규칙으로 맞췄습니다.

해설 위치 이름의 형태	처리	해당 수
백엔드에 같은 이름의 위치가 있음 (예: 근정전)	그 위치에 그대로	29곳
여러 전각을 가운뎃점으로 묶은 이름 (예: 협길당·함화당·흥복전)	전각마다 같은 목록	23곳
권역 묶음 (태원전 일곽, 건청궁 부속)	그 권역의 나머지 부속 건물 전부에 같은 목록	19곳
기타	대응하는 위치가 없어 제외	0곳

이 규칙으로 71곳 모두에 목록이 붙었습니다. 여러 위치가 같은 내용의 단어집을 갖게 되지만, 백엔드가 위치 id로만 단어집을 찾기 때문에 이름을 위치마다 따로 두었습니다.

3.5 묶음 이름 3개를 단어에서 뺀 이유

위치별 목록을 만드는 스크립트는 해설 위치 이름을 가장 중요한 단어로 보고 목록 맨 앞에 넣습니다. "근정전" 목록의 첫 단어가 "근정전"이 되는 식이라 대부분은 맞는 동작입니다. 그런데 "기타", "건청궁 부속", "태원전 일곽"은 전각 이름이 아니라 문장을 묶어 둔 구역 이름인데도 똑같이 들어가 있었습니다.

- "기타"는 흔한 일상어라 받아쓰기에서 강조할 이유가 없습니다.
- 교정 사전도 같은 목록을 쓰므로, 비슷하게 들린 말이 이 이름들로 잘못 고쳐질 여지가 있습니다.

그래서 백엔드용으로 내보낼 때 이 세 이름을 뺐습니다. 벤치마크 원본 파일은 예전 측정과 조건을 맞추기 위해 그대로 두었습니다.

3.6 번역 용어집을 영어만 올린 이유

처음에는 영어·태국어를 함께 올렸는데 등록이 거부됐습니다. Translate는 용어 하나가 200바이트를 넘으면 받지 않습니다.

점검 항목	값
용어집 전체 행	329
200바이트를 넘는 행	8 (모두 태국어 칸)
가장 긴 영어 표기	113바이트
가장 긴 태국어 표기	300바이트

넘은 8행은 모두 묶음 항목입니다(창건·중건·재건·복원·소실 5행, 일월오봉도·일월오봉병 2행, 인·의·예·지·신 1행). 태국어는 글자 하나가 3바이트라 같은 내용도 영어보다 훨씬 길어집니다.

영어를 먼저 검증하고 태국어는 그 뒤에 한다는 방침에 따라, 태국어 칸을 빼고 영어만 올렸습니다. 이렇게 하면 한도에 걸리는 행이 없습니다. 태국어를 추가하려면 이 8행을 먼저 정리해야 합니다.

3.7 등록 결과

항목	결과
Transcribe 단어집	72개 모두 준비됨, 실패 0개
등록에 걸린 시간	10분 34초
Translate 용어집	329행 등록, 한국어 → 영어
팀 계정 단어집 한도	계정당 100개 중 72개 사용

3.8 원본 자료에서 발견한 것

등록과 채점 준비 과정에서 용어집과 엑셀을 대조하다가 다음을 발견했습니다.

발견한 것	내용
꽃담의 영문 표기가 엑셀끼리 다름	`경복궁_전각.xlsx`는 Kkotdam (Decorative Brick Wall), `경복궁_용어.xlsx`는 Kkotdam (Decorative Flower Wall). 용어집은 전각 엑셀 쪽을 따름
가운뎃점이 든 용어	용어집에는 "인·의·예·지·신"으로 들어 있으나 해설 문장과 받아쓰기 결과는 "인의예지신". 글자가 달라 용어집이 적용되지 않음
용어집에 없는 표기 8개	칸, 사신(외국 사신과 사신도의 사신이 같은 글자), 옥당, 조대비, 익종, 지정번호, 문화재청
전각 71개	용어집의 영어와 `경복궁_전각.xlsx`의 `name_en`이 모두 같음

4. 현장 녹음 받아쓰기

4.1 녹음

2026-11-08 경복궁 현장에서 녹음한 파일 2개입니다(m4a, 48 kHz, 한 채널). 벤치마크 문장 가운데 전각별로 3개씩 뽑은 읽기 문장의 일부를 읽었습니다.

녹음	길이(초)	읽은 곳	문장 수
녹음 1	72.4	광화문 3, 흥례문 3, 건춘문 2	8
녹음 2	54.1	근정전 조정 3, 근정전 3, 근정전 내부 1	7

녹음 1의 끝에서 건춘문 세 번째 문장은 첫 글자에서 녹음이 끊겨 정답에서 뺐습니다.

4.2 측정 방법과 선택 이유

선택	내용	이유
녹음 나누기	두 녹음을 전각이 바뀌는 지점에서 6구간으로 자름	실제 해설에서는 위치가 바뀌면 단어집도 바뀜. 구간마다 그 전각의 단어집을 붙여야 서비스와 같은 조건이 됨
자르는 지점	말소리가 끊기는 쉬는 구간의 가운데	문장 중간을 자르면 그 자체로 오류가 생김
단어집	팀 계정에 등록한 위치별 단어집	3장에서 등록한 자원이 실제로 작동하는지도 함께 확인
말소리 구간 검출	끔	Transcribe 자체의 성능을 보려는 측정임. 검출 단계를 켜면 오류가 어느 쪽에서 났는지 가릴 수 없음. 백엔드의 현재 코드도 받은 소리를 그대로 Transcribe에 보냄
보내는 속도	실제 말하는 속도로 0.1초씩	실시간 받아쓰기와 같은 조건
교정 사전	위치별 용어 목록, 소리 유사도 0.85 이상이면 교정	벤치마크·백엔드와 같은 설정
CER 계산	벤치마크와 같은 규칙(공백·문장부호 제거, 숫자는 한글 읽기로 통일)	조용한 녹음 결과(3.7%)와 바로 비교하기 위함

4.3 결과

구간	글자 수	교정 전 CER (↓ 낮을수록 좋음)	교정 후 CER (↓)
광화문 (3문장)	115	4.3%	3.5%
흥례문 (3문장)	121	5.8%	4.1%
건춘문 (2문장)	78	14.1%	11.5%
근정전 조정 (3문장)	104	10.6%	9.6%
근정전 (3문장)	91	14.3%	12.1%
근정전 내부 (1문장)	33	3.0%	3.0%
전체 (15문장)	542	8.9%	7.4%
참고: 조용한 녹음 180문장			3.7%

6구간 모두 연결 오류 없이 끝났고, 문장이 통째로 사라지거나 엉뚱한 문장으로 바뀐 경우는 없었습니다.

4.4 어떤 단어가 틀렸는가

구간	정답	받아쓴 글	교정 사전 적용 뒤
광화문	홍예문	통회문	통회문 (그대로)
광화문	문루	문구	**문루**
흥례문	흥례문	흑미문	흑미문 (그대로)
흥례문	흥례문	흉례문	**흥례문**
흥례문	흥례문	흑례문	**흥례문**
흥례문	예가	얘가	얘가 (그대로)
흥례문	헐렸습니다	걸렸습니다	걸렸습니다 (그대로)
건춘문	건춘문 (2번)	건축문	**건춘문**
건춘문	관원들이	(빠짐)	(빠짐)
근정전 조정	신년 하례	10년 할례	10년 **하례**
근정전 조정	사신 접견	사신접경	사신접경 (그대로)
근정전 조정	의례	의뢰	의뢰 (그대로)
근정전 조정	품계석	통계석	통계석 (그대로)
근정전	다포계	다포의	**다포계**
근정전	팔작지붕	팔짝 지붕	팔짝 지붕 (그대로)
근정전	십이지신상	시위 지신상	시위 지신상 (그대로)
근정전	하례	할례	**하례**
근정전	사신 접견	사신접변	사신접변 (그대로)

4.5 해석

- **교정 사전이 8건을 바로잡았습니다.** 건춘문 2건, 흥례문 2건, 하례 2건, 문루, 다포계입니다. 받아쓴 글이 정답과 한두 글자만 다른 경우에 잘 작동합니다.
- **소리가 크게 달라진 단어는 남았습니다.** 통회문(홍예문), 흑미문(흥례문), 통계석(품계석)은 정답과의 유사도가 교정 기준(0.85)에 못 미쳤습니다.
- **용어 목록에 없는 일반 단어는 교정 대상이 아닙니다.** 접견, 의례, 신년, 헐렸습니다가 여기에 해당합니다.
- **CER에는 낭독 차이도 들어 있습니다.** 정답을 읽기 문장으로 잡았는데 실제 낭독은 몇 군데 달랐습니다. "전해집니다"를 "합니다"로, "근정문에서"를 "근정전에서"로 읽었고, "네", "음" 같은 말과 "상하 이층 … 상하 이단"으로 고쳐 말한 부분이 있습니다. 다른 받아쓰기 엔진(Whisper)으로 받아써도 같은 곳이 같은 말로 나와 낭독 차이로 판단했습니다. 따라서 Transcribe만의 오류율은 표의 값보다 낮습니다.
- **읽은 문장의 용어는 모두 단어집에 들어 있습니다.** 위치별 목록을 이 문장들이 포함된 해설 문장 300개에서 만들었기 때문입니다. 해설사가 목록에 없는 용어를 말하는 경우는 이 측정에 들어 있지 않습니다.
- **문장 수가 15개라 수치는 참고용입니다.** 한 글자가 0.2%에 해당하므로, 숫자보다 "어떤 종류의 단어가 틀리는가"가 이 측정의 주된 결과입니다. 틀린 단어는 대부분 전각 이름과 궁궐 용어이고, 이는 조용한 녹음에서 본 경향과 같습니다.

5. 영어 번역 용어집 평가

5.1 무엇을 평가했고 왜 이 지표인가

평가한 것은 **"문장에 든 용어가 영어 결과에서 엑셀에 정한 영문 표기 그대로 나오는가"** 입니다.

- **요구사항과 직접 맞닿아 있습니다.** 자막의 전각 이름과 용어는 `경복궁_전각.xlsx`의 `name_en`, `경복궁_용어.xlsx`의 "영문 표기 (작성용)"을 따르기로 했습니다.
- **맞고 틀림이 분명해 자동으로 셀 수 있습니다.** 영어 결과 안에 정해진 표기가 들어 있는지만 보면 됩니다.
- **문장 전체의 품질은 자동으로 채점할 기준이 없습니다.** 흔히 쓰는 자동 점수는 사람이 만든 정답 번역과 비교하는데, 정답 영어 번역문이 없습니다.
- **우리가 고칠 수 있는 부분이 용어집입니다.** 문장을 매끄럽게 옮기는 능력은 Translate 자체의 성능이고, 용어 표기는 용어집으로 우리가 정하는 부분입니다.

5.2 왜 녹음이 아니라 정답 글 300문장인가

- **번역만의 성적을 보기 위해서입니다.** 받아쓴 글에는 오류가 섞여 있어, 영어가 이상할 때 번역 탓인지 받아쓰기 탓인지 가릴 수 없습니다. 정답 글을 넣으면 번역과 용어집만의 결과가 나옵니다.
- **300문장에 용어가 전부 들어 있습니다.** 엑셀의 이름 330개가 300문장 안에 모두 한 번 이상 나옵니다. 녹음이 있는 180문장만 쓰면 일부 용어가 빠집니다.
- **문장마다 어떤 용어가 들었는지 이미 적혀 있습니다.** 해설 문장 엑셀의 "포함 용어", "포함 전각명" 칸을 채점 기준으로 썼습니다.

5.3 채점 방법

1. 해설 문장 300개와 문장별 포함 용어·전각 이름을 읽습니다.
2. 용어마다 "영어 결과에 나와야 하는 표기"를 정합니다. 기준은 팀 계정에 올린 용어집의 영어 칸이고, 이것이 엑셀 두 개의 영문 표기와 같은지 대조했습니다(3.8절).
3. 문장을 하나씩 Translate에 보내 영어를 받습니다. 용어집을 붙인 경우와 붙이지 않은 경우, 두 번 합니다.
4. 용어마다 기대 표기가 영어 결과에 들어 있으면 일치로 셉니다.

용어집을 켠 것과 끈 것을 모두 돌린 이유. 끈 결과가 있어야 용어집이 실제로 얼마나 바꾸는지 알 수 있습니다. Translate가 용어집 없이도 같은 표기를 낸다면 용어집의 효과가 아니기 때문입니다.

채점에서 무시한 차이. Translate는 용어집의 표기를 넣으면서 빗금 주변의 띄어쓰기를 없애고(`A / B` → `A/B`) 굽은 따옴표를 곧은 따옴표로 바꿉니다. 표기 자체는 적용된 것이므로 대소문자, 빗금 주변 띄어쓰기, 따옴표 모양의 차이는 일치로 봤습니다.

채점 대상	개수
문장	300
문장에 든 용어	510
문장에 든 전각 이름	283
채점한 항목(기대 표기가 정해진 것)	772 (서로 다른 표기 312종)
채점에서 뺀 항목	21

뺀 21개는 용어집에 없는 단어 19개(사신, 칸 등)와, 문장의 글자가 용어집과 달라 대응시킬 수 없는 2개(인의예지신)입니다.

5.4 결과

구분	항목 수	용어집 켬 일치율 (↑ 높을수록 좋음)	용어집 끔 일치율 (↑)
전체	772	18.0%	0.3%
용어	489	18.4%	0.4%
전각 이름	283	17.3%	0.0%
용어 뒤가 띄어쓰기·문장부호	216	63.0%	0.5%
용어 뒤에 조사가 붙음	556	0.5%	0.2%

- **용어집이 없으면 정해진 표기는 거의 나오지 않습니다(0.3%).** 용어집은 필요합니다.
- **용어집을 붙여도 18%입니다.** 채점 항목이 있는 문장 296개 중 모든 용어가 맞은 문장은 5개입니다.
- **312종 중 224종은 한 번도 정해진 표기로 나오지 않았습니다.**

5.5 조사가 붙으면 용어집이 적용되지 않습니다

결과를 "용어 바로 뒤 글자가 한글인가"로 나누자 차이가 뚜렷했습니다. 이렇게 나눠 본 이유는, 용어집이 적용된 문장과 안 된 문장을 나란히 놓았을 때 같은 단어가 조사 유무에 따라 다르게 나오는 것이 보였기 때문입니다.

한국어	영어 결과	용어집 적용
2023년에는 **광화문 앞** 월대도 복원됐습니다.	… in front of **Gwanghwamun (Palace Gate)** …	적용됨
광화문은 경복궁의 정문이자 남문으로 …	**Gwanghwamun** is the main gate …	적용 안 됨
… **강녕전**, 흠경각과 함께 소실됐다가 …	… **Gangnyeongjeon (King's Bedchamber)** …	적용됨
강녕전은 임금의 침전입니다.	**Gangnyeongjeon** is the deposition of wages.	적용 안 됨

해설 문장에서 용어 772번 중 556번(72%)은 조사가 붙어 나옵니다. 붙은 글자는 다음과 같습니다.

용어 뒤에 붙은 글자	횟수
은	122
에	62
이	53
을	44
과	39
의	35
를	29
는	25
으(으로)	25
가	20

한국어는 명사 뒤에 조사를 붙여 쓰는 것이 기본이므로, 이 문제는 일부 문장의 예외가 아니라 용어 대부분에 해당합니다.

5.6 조사가 없어도 적용되지 않은 경우

용어 뒤가 띄어쓰기나 문장부호인 216번 중 80번(37%)도 정해진 표기로 나오지 않았습니다. "건춘문 북쪽"이 "Geonchunmun Gate"로, "신무문 현판"이 "Shinmu-mun"으로 나온 식입니다. 많이 나온 것은 태원전(6), 자경전(4), 근정전(3), 강녕전(3), 국상(3), 수정전(3)입니다.

5.7 묶음 항목

용어집에는 여러 용어를 한 줄로 묶어 같은 영문 표기를 준 항목이 있습니다. 300문장에 39종이 124번 나왔고, 그중 20번이 일치했습니다.

한국어	용어집의 영문 표기	실제 결과
홍예문	Hongye / Hongyemun (arch)	three **Hongye/Hongyemun (arch)** on a …
신정왕후	Sinjeongwanghu / Jodaebi (Queen Sinjeong)	**Sinjeongwanghu/Jodaebi (Queen Sinjeong)**, or Jo Dae-bi
창건	Changgeon / Junggeon / Jaegeon / Bogwon / Sosil (Foundation / Reconstruction / Restoration / Destruction by Fire)	(조사가 붙어 적용되지 않음)

적용된 경우에도 한 단어 자리에 여러 이름이 빗금으로 이어져 나와 자막으로 읽기에 어색합니다. "창건", "소실"처럼 뜻이 서로 다른 단어가 한 묶음인 항목은, 적용되면 "소실"이 다섯 단어 묶음으로 번역됩니다.

5.8 용어집이 적용되지 않은 문장의 오역

용어집이 적용되지 않으면 Translate는 전각 이름과 궁궐 용어를 일반 단어로 해석합니다.

한국어	Translate 결과	잘못된 부분
사정전은 임금이 평소에 정사를 보던 편전입니다.	The situation war is a situation where the king usually sees the situation.	사정전·정사·편전을 모두 "사정/상황"으로 옮김
강녕전은 임금의 침전입니다.	Gangnyeongjeon is the deposition of wages.	임금(왕)을 임금(급여)으로, 침전(침실)을 침전(가라앉음)으로 옮김
자경전은 대비의 침전이고 …	Jagyungjeon is a sedimentation of contrast …	대비(왕의 어머니)를 대비(비교)로 옮김
… 임금과 세자, 중국 사신만 …	Only kings, tax rulers, and Chinese messengers …	세자를 세금 관련 단어로 옮김
조선총독부 청사	the DPRK Governor's Office	조선을 북한으로 옮김
집옥재는 … 고종의 서재이자 …	House okjae means …	집옥재의 "집"을 house로 옮김

궁궐 해설은 같은 글자의 일상어가 있는 한자어가 많아서, 용어집이 적용되지 않으면 문장의 뜻이 통째로 바뀝니다. 용어 표기 일치율이 낮다는 것은 표기가 조금 다른 수준이 아니라 이런 오역이 자막에 나간다는 뜻입니다.

5.9 번역 속도와 비용

항목	값
번역 호출	600번 (300문장 × 2)
보낸 글자	25,460자
문장 하나 번역 시간, 가운데값 (↓ 낮을수록 좋음)	108ms
문장 하나 번역 시간, 느린 쪽 10% 경계 (↓)	173ms
번역 비용	약 0.38달러
현장 녹음 받아쓰기 비용(약 2분)	약 0.05달러

번역 단계는 문장당 0.1~0.2초로, 자막 지연 목표(문장 끝에서 자막까지 3초)에서 차지하는 몫이 작습니다.

6. 용어 표기 일치율을 높이는 방법 시험

5장의 18.0%를 끌어올리기 위해 두 가지 방법을 시험했습니다. 둘 다 5장과 같은 300문장, 같은 772개 항목, 같은 채점 규칙으로 쟀으므로 숫자를 그대로 비교할 수 있습니다.

6.1 번역이 끝난 영어를 유사도로 한 번 더 고치기

받아쓰기의 교정 사전과 같은 원리(자로-윙클러 유사도)를 영어 결과에 적용하는 방법입니다. Translate가 전각 이름을 소리대로 적기는 했는데 철자가 정해진 표기와 다른 경우(`Gyotae-jeon`, `Jagyungjeon`)를 잡으려는 것입니다.

방법

1. 문장의 한국어 원문에 든 용어를 확인하고, 그 용어들의 영문 표기만 후보로 둡니다.
2. 영어 결과에서 낱말 1~3개씩을 묶어, 표기의 이름 부분(괄호 앞)과 글자를 비교합니다.
3. 유사도가 기준 이상인 자리 가운데 가장 비슷한 곳을 정해진 표기로 바꿉니다.

선택	이유
후보를 그 문장에 든 용어로만 제한	용어집 329개 전체와 견주면 관계없는 영어 단어까지 바뀜
낱말 1~3개를 묶어서 비교	Translate가 이름을 `Hum Kyunggak`처럼 띄어 쓰거나 `Gyotae-jeon`처럼 붙임표를 넣음
글자만 비교(대소문자·붙임표·띄어쓰기 무시)	위와 같은 이유
이름 뒤의 Gate·Hall 등은 함께 바꿈	`Geonchunmun Gate`를 `Geonchunmun (Palace Gate) Gate`로 만들지 않기 위함
기준값 0.85를 중심으로 0.80~0.95 비교	0.85는 받아쓰기 교정 사전에서 쓰는 값. 영어에서도 맞는 값인지 보기 위해 위아래를 함께 잼

결과

유사도 기준	고친 자리	일치율 (↑ 높을수록 좋음)
교정 없음(용어집만)	0	18.0%
0.95	195	43.3%
0.90	244	49.2%
0.85	277	53.1%
0.80	309	56.7%

기준 0.85일 때	고치기 전 (↑)	고친 뒤 (↑)
전각 이름 (283개)	17.3%	80.6%
용어 (489개)	18.4%	37.2%

- **고친 277자리 중 177자리는 철자가 이미 같았습니다.** `Gwanghwamun`처럼 이름은 맞게 나왔는데 괄호 설명이 없던 것입니다. 나머지 100자리가 철자가 달랐던 것입니다.
- **전각 이름에 잘 듣습니다.** 전각 이름은 Translate가 소리대로 적는 경우가 많아 비슷한 글자가 영어 결과에 남아 있습니다.
- **용어에는 덜 듣습니다.** 침전, 행각, 편전 같은 용어는 Translate가 뜻을 풀어 다른 단어로 옮기므로(`deposition`, `surrounding areas`) 영어 결과에 비슷한 글자가 없습니다. 교정 뒤에도 362건이 남습니다.

잘못 고친 경우

유사도 0.85~0.90 구간의 33자리를 직접 읽어 보니 7자리가 잘못 고친 것이었습니다.

용어	바뀐 영어 단어	문제
조선총독부, 조선왕조실록, 조선고적도보	Joseon	긴 표기의 앞부분만 겹친 다른 자리의 단어를 바꿈
석축	Seokbun	다른 용어(석분)의 표기를 바꿈
관아	Gwanghwamun (Palace	이미 맞게 들어간 광화문 표기를 깨뜨림
복원	Jungangcheong	관계없는 이름(중앙청)을 바꿈

기준을 낮출수록 일치율은 오르지만 이런 경우도 함께 늘어납니다.

6.2 번역 전에 용어를 영문 이름으로 바꿔 넣기

5.8절의 오역은 Translate가 "사정전", "침전" 같은 한국어 단어를 보고 일상어로 풀어서 생깁니다. 그래서 Translate가 그 단어를 보기 전에 정해진 영문 이름으로 바꿔 두는 방법을 시험했습니다. 조사는 그대로 두고 용어 부분만 바꾸므로, 조사가 붙었는지와 상관이 없습니다.

방법

1. 문장에서 용어를 찾아 영문 표기로 바꿉니다. 긴 용어부터 바꾸고, 겹치는 자리는 건너뜁니다.
2. 한국어와 영어가 섞인 문장을 Translate에 보냅니다.
3. 받은 영어에 정해진 표기가 들어 있는지 채점합니다.

넣는 방식은 두 가지를 비교했습니다.

방식	보내는 문장
원문	사정전은 임금이 평소에 정사를 보던 편전입니다.
설명까지 넣기	Sajeongjeon (Royal Council Hall)은 임금이 평소에 정사를 보던 Pyeonjeon (Royal Council Hall)입니다.
이름만 넣기	Sajeongjeon은 임금이 평소에 정사를 보던 Pyeonjeon입니다. → 번역이 끝난 뒤 이름 뒤에 괄호 설명을 붙임

선택	이유
두 방식을 모두 시험	끼워 넣는 글자가 짧을수록 Translate가 건드릴 여지가 줄어드는지 확인. 번역 요금이 글자 수에 비례하므로 비용 차이도 큼
용어집은 붙이지 않음	바꿔 넣기만의 효과를 보기 위함
바꾸는 대상은 5장과 같은 772자리	5장의 결과와 같은 항목으로 비교하기 위함
설명을 붙일 때 이름을 낱말 단위로 찾음	`Geunjeongjeon` 안의 `Jeongjeon`처럼 다른 이름 안에 든 글자를 건드리지 않기 위함

결과

방식	전체 (↑ 높을수록 좋음)	용어 (↑)	전각 이름 (↑)	용어 뒤가 띄어쓰기·문장부호 (↑)	용어 뒤에 조사 (↑)
용어집만	18.0%	18.4%	17.3%	63.0%	0.5%
바꿔 넣기, 설명까지	84.1%	75.3%	99.3%	86.1%	83.3%
바꿔 넣기, 이름만 넣고 설명은 뒤에	94.2%	90.8%	100.0%	95.4%	93.7%

- **조사 문제가 사라졌습니다.** 용어집만 쓸 때 62.5%포인트이던 조사 유무의 차이가, 이름만 넣는 방식에서는 1.7%포인트입니다.

- **Translate는 끼워 넣은 이름을 95.6% 그대로 두었습니다**(772자리 중 738자리).
- **전각 이름은 283개가 모두 맞았습니다.**
- **이름만 넣는 쪽이 낫습니다.** 설명까지 넣으면 Translate가 괄호 안의 설명을 다시 번역해서 표기가 달라집니다. `Covered Corridors Surrounding a Building`이 `Covered Corridors Corridors a Building`으로, `Stone Retaining Wall`이 `Stone Wall`로 바뀌었습니다.

남은 45건

종류	건수	내용
여러 이름을 묶은 표기를 Translate가 일부 바꾸거나 뺌	27	복원 18, 이익공·익공 4, 창건 2, 재건·중건·재실 각 1. `Changgeon / Junggeon / Jaegeon / Bogwon / Sosil`이 통째로 들어가 일부가 바뀜
긴 용어 안에만 들어 있어 따로 들어가지 않음	6	십장생(십장생 굴뚝) 3, 품계(품계석) 1, 조정(근정전 조정) 1, 중건(경복궁 중건) 1. 긴 용어가 통째로 바뀌므로 짧은 용어의 표기는 나올 자리가 없음
영어 구절로 된 표기를 다시 번역	4	경복궁 중건. `Reconstruction of Gyeongbokgung Palace`를 문장 속에서 풀어 옮김
복수형 s를 붙임	4	신료 2, 공신 1, 오복 1. `Sillyo`가 `Sillyos`로
철자를 바꾸거나 빠뜨림	4	문루 2(`Mullu`가 `Mulu`로), 모사 1(`mosaze`), 봉안 1(결과에서 사라짐)

이름만 넣는 방식	맞은 수	일치율 (↑)
묶음 항목이 아닌 것	687 / 705	97.4%
묶음 항목	40 / 67	59.7%

5.8절의 문장이 어떻게 바뀌었는가

원문	용어집만	이름만 바꿔 넣기
강녕전은 임금의 침전입니다.	Gangnyeongjeon is the deposition of wages.	Gangnyeongjeon (King's Bedchamber) is the king's Chimjeon (royal bedchamber hall).
교태전은 왕비의 침전으로 중궁전이라고도 불렸습니다.	Gyotae-jeon was also called the Middle Palace due to the Queen's death.	Gyotaejeon (Queen's Bedchamber) was the queen's Chimjeon (royal bedchamber hall) and was also called Junggungjeon (Residence of the Queen Consort).
자경전은 대비의 침전이고 …	Jagyungjeon is a sedimentation of contrast …	Jagyeongjeon (Queen Dowager's Residence) is Daebi (Queen Dowager)'s Chimjeon (royal bedchamber hall) …
… 조선총독부 청사를 짓는다는 이유로 …	… the DPRK Governor's Office building.	… the Joseon Chongdokbu (Japanese Government-General of Korea) Government Building.
소주방은 왕실 음식을 장만하던 궁궐의 부엌입니다.	The small kitchen is the kitchen of the palace …	Sojubang (Royal Kitchen) is the palace kitchen …

6.3 번역 뒤 후처리 규칙 두 가지

6.2절의 남은 45건 가운데 복수형 4건과 철자 변경 3건은, 번역을 다시 돌리지 않고 설명을 붙이는 단계의 규칙만으로 풀 수 있습니다. 이미 받아 둔 번역 결과에 규칙을 적용해 확인했습니다.

규칙	내용
복수형 인정	설명을 붙일 이름을 찾을 때, 이름 뒤에 s가 붙은 것도 같은 이름으로 봄
철자 되돌리기	넣은 이름이 결과에 없을 때, 그 이름과 유사도 0.90 이상인 낱말 하나를 그 이름으로 바꿈

철자 되돌리기에는 조건을 좁게 걸었습니다. 6.1절에서 유사도만으로 고치면 맞게 나온 다른 이름을 깨뜨리는 경우가 나왔기 때문입니다.

- 넣은 이름이 결과에서 사라졌을 때만 찾습니다.
- 한 낱말로 된 이름만 대상으로 합니다.
- 다른 용어의 이름이거나 사전에 있는 일반 영어 낱말이면 건드리지 않습니다.

적용한 규칙	맞은 수	일치율 (↑ 높을수록 좋음)	바뀐 자리
규칙 없음	727 / 772	94.2%	0
복수형 인정	731 / 772	94.7%	4
복수형 인정 + 철자 되돌리기	734 / 772	95.1%	7

바뀐 7자리(`Mulu` 2, `mosaze` 1, `Sillyos` 2, `Gongsins` 1, `Oboks` 1)를 모두 읽어 확인했고, 잘못 바꾼 곳은 없습니다.

6.4 넣은 이름에 번역 제외 표시 씌우기

6.2절에서 남은 문제는 대부분 "넣어 준 이름을 Translate가 바꾼 것"입니다. Translate에는 HTML 요소에 `translate="no"`를 붙이면 그 안을 번역하지 않는 기능이 있어(공식 문서), 넣은 이름을 이 표시로 감싸 보내는 방법을 시험했습니다.

방법

1. 6.2절처럼 용어를 영문 이름으로 바꾸되, 이름을 `<span translate="no">…</span>`로 감쌉니다.
2. Translate에 보냅니다.
3. 받은 영어에서 표시가 있는 자리에 정해진 표기(괄호 설명 포함)를 넣습니다. 표시가 자리를 알려 주므로 이름을 다시 찾을 필요가 없습니다.

	문장
보낸 문장	경복궁을 처음 `<span translate="no">Changgeon / Junggeon / Jaegeon / Bogwon / Sosil</span>`한 1395년에는 `<span translate="no">Gungseong</span>`이 없어서 …
받은 문장	In 1395, when Gyeongbokgung Palace was first `<span translate="no">Changgeon / Junggeon / Jaegeon / Bogwon / Sosil</span>`, there was no `<span translate="no">Gungseong</span>`, …

선택	이유
300문장이 아니라 37문장만 번역	6.3절까지 하고도 안 맞는 38건이 이 37문장에 모두 들어 있음. 번역 비용을 줄이기 위함
같은 37문장의 다른 항목도 함께 채점	이 문장들에는 이미 맞던 항목 81건도 있어, 표시를 씌웠을 때 깨지는 것이 있는지 볼 수 있음
표시 안에는 이름만 넣음	6.2절에서 이름만 넣는 쪽이 나았음

결과

확인한 것	결과
보낸 표시	114개
내용이 그대로 돌아온 표시	114개
안 맞던 38건 중 새로 맞은 것	32건
이미 맞던 81건 중 틀리게 된 것	0건
37문장의 채점 항목 119건	81건 일치 → 113건 일치

- **조사가 바로 붙은 자리에서도 표시가 작동했습니다.** 위 예의 "…Sosil `</span>` 한"처럼 표시 바로 뒤에 한국어가 붙어도 안의 이름은 바뀌지 않았습니다.
- **300문장 전체로 환산하면 766 / 772, 99.2%입니다.** 37문장은 실제 결과이고, 나머지 263문장은 6.3절의 결과가 그대로라고 본 값입니다.
- **6.3절의 후처리 규칙은 필요 없어집니다.** 표시가 이름의 자리를 그대로 알려 주기 때문에 철자를 되돌리거나 복수형을 찾을 일이 없습니다.
- **남은 6건은 긴 용어 안에 든 짧은 용어입니다**(십장생 3, 품계 1, 조정 1, 중건 1). 번역 방식으로는 풀 수 없고, 채점에서 이 항목을 어떻게 셀지 정해야 합니다.

일치율이 올라도 남는 문제

여러 이름을 묶은 표기는 정확히 들어가서 일치로 세지만, 문장은 여전히 어색합니다.

원문	결과
경복궁을 처음 창건한 1395년에는 …	… was first Changgeon / Junggeon / Jaegeon / Bogwon / Sosil (Foundation / Reconstruction / Restoration / Destruction by Fire) …
협길당은 물익공 건물이고 …	… is a water Ikgong / Iikgong / Choikgong (wing-like bracket) building …

묶음 표기를 용어마다 나누는 일은 일치율과 별개로 필요합니다.

6.5 방식 비교

방식	전체 일치율 (↑ 높을수록 좋음)	용어 (↑)	전각 이름 (↑)
용어집만	18.0%	18.4%	17.3%
용어집 + 영어 유사도 교정 (0.85)	53.1%	37.2%	80.6%
번역 전에 바꿔 넣기, 설명까지	84.1%	75.3%	99.3%
번역 전에 바꿔 넣기, 이름만 넣고 설명은 뒤에	94.2%	90.8%	100.0%
위 방식 + 후처리 규칙 두 가지	95.1%	92.2%	100.0%
위 방식 + 번역 제외 표시 (37문장 측정, 나머지 환산)	99.2%	98.8%	100.0%

바꿔 넣기는 Translate가 용어의 뜻을 잘못 푸는 것을 막고, 번역 제외 표시는 넣어 준 이름을 Translate가 바꾸는 것을 막습니다. 둘을 함께 쓰면 영어 결과를 유사도로 고치는 단계 없이도 99% 수준이 됩니다.

6.6 글자 수와 비용

번역 요금은 보내는 글자 수에 비례합니다. 한국어 용어를 영어로 바꿔 넣으면 글자 수가 늘어납니다.

방식	보낸 글자 수 (↓ 낮을수록 좋음)	원문 대비
원문 그대로	12,730	1배
이름만 넣기	20,103	1.6배
설명까지 넣기	39,824	3.1배
이름만 넣기 + 번역 제외 표시 (300문장에 모두 씌울 때의 계산값)	41,719	3.3배

이름만 넣는 방식은 설명까지 넣는 방식보다 일치율이 높으면서 글자 수도 절반입니다. 번역 제외 표시는 이름 하나마다 28글자를 더하므로, 표시 글자까지 세면 글자 수가 설명까지 넣는 방식과 비슷해집니다.

이 장의 시험에 쓴 번역 비용은 바꿔 넣기 두 방식(300문장씩)이 약 0.90달러, 번역 제외 표시(37문장, 6,796자)가 약 0.10달러입니다.

6.7 이 방법으로 잡히지 않는 것

용어집에 없는 일반 단어의 오역은 그대로 남습니다.

원문	이름만 바꿔 넣은 결과	잘못된 부분
사정전은 임금이 평소에 정사를 보던 편전입니다.	Sajeongjeon (Royal Council Hall) is a Pyeonjeon (Royal Council Hall) whose wages are usually involved.	임금(왕)을 급여로 옮김
집옥재는 … 고종의 서재이자 외국 사신을 만나던 곳입니다.	Jibokjae (Royal Library) … a place where I met foreign messengers.	사신을 messengers로, 주어를 I로 옮김
품계석은 … 정1품부터 정9품까지 …	… from 1 to 9 genuine products …	정1품(벼슬 등급)을 정품(진짜 물건)으로 옮김

용어 표기 일치율은 "정해진 표기가 들어 있는가"만 보므로, 이런 문장도 일치로 셉니다. 일치율 94.2%가 문장의 94.2%가 옳게 번역됐다는 뜻은 아닙니다.

7. 결론과 다음 단계

결론

- 받아쓰기는 현장 소음에서도 문장 단위로 안정적으로 작동하고, 위치별 단어집과 교정 사전의 조합이 현장에서도 유효합니다.
- 번역은 용어집을 등록하는 것만으로는 용어의 18%만 정해진 표기로 나옵니다. 조사가 붙은 용어에 용어집이 적용되지 않기 때문입니다.
- 번역하기 전에 용어를 영문 이름으로 바꿔 넣으면 94.2%, 그 이름에 번역 제외 표시까지 씌우면 99.2%(환산)가 됩니다. Translate 용어집의 동작에 기대지 않는 방법입니다.
- 자막 품질을 좌우하는 것은 받아쓰기보다 번역 단계의 용어 처리입니다.

다음 단계

순서	할 일	목적
1	정해야 할 영문 표기 정하기: 묶음 표기를 용어마다 한 줄로 나눈 표기, 용어집에 없는 사람·건물 이름의 표기, 창건·복원·소실처럼 로마자 대신 일반 영어로 둘 말	묶음 표기가 문장을 어색하게 만드는 문제와 6.7절의 오역을 줄이는 데 필요. 태국어 200바이트 한도 문제도 함께 풀림
2	표기가 정해진 뒤 300문장 전체를 "이름만 바꿔 넣기 + 번역 제외 표시"로 한 번에 다시 측정	99.2%는 37문장 측정과 환산을 합친 값이므로 전체를 실제로 확인. 자주 틀리는 일반 단어(임금, 전각 등)를 쉬운 말로 바꿔 보내는 처리도 함께 시험
3	같은 처리를 실시간 파이프라인의 번역 단계 앞뒤에 넣기	이번 시험은 엑셀에 적힌 포함 용어를 썼음. 실제 흐름에서는 교정 사전 단계가 찾은 용어 위치를 씀
4	긴 용어 안에 든 짧은 용어 6건을 채점에서 어떻게 셀지 정하기	번역 방식으로는 풀 수 없는 항목을 채점 기준에서 정리
5	현장 녹음을 받아쓴 글에 같은 처리를 적용해 번역하고, 문장 끝에서 자막까지의 지연 측정	받아쓰기와 번역을 이어 붙인 실제 자막 품질과 지연 확인
6	원본 표기 정리(꽃담 영문 표기 통일, "인·의·예·지·신"의 가운뎃점 없는 표기 추가)와 태국어 용어집	용어집과 실제 문장의 글자를 맞추고, 영어 검증이 끝난 뒤 태국어로 넓힘

부록. 파일 위치

파일	내용
`results_translate/terms300_summary.csv`	5.4절 요약표
`results_translate/terms300_by_term.csv`	용어별 등장 수, 일치 수, 조사가 붙어 나온 수
`results_translate/terms300_scored.jsonl`	문장별 한국어, 영어 결과 두 가지, 용어별 일치 여부
`results_translate/inject300_summary.csv`	6.5절 방식 비교표
`results_translate/inject300_scored.jsonl`	문장별로 바꿔 넣어 보낸 문장, 받은 영어, 유사도 교정 결과, 후처리 규칙 적용 결과, 용어별 일치 여부
`results_translate/notrans37_scored.jsonl`	번역 제외 표시 시험 37문장: 보낸 문장, 받은 영어, 항목별 전후 일치 여부
`gunggeum-ai-stt/gunggeum_stt/be_export.py`	위치별 목록을 백엔드 위치 71곳 기준으로 바꾸고 팀 계정에 등록하는 코드
`gunggeum-ai-stt/gunggeum_stt/data/hints_by_location.json`	위치별 용어 목록 원본(37개)
`gunggeum-ai-stt/gunggeum_stt/data/translate_terms.csv`	번역 용어집 원본(329행)